一、知识框架总览

离散信息的度量体系分为两大维度：

1. 单个事件的信息度量

- 自信息 I(x)
- 条件自信息 I(x|y)
- 联合自信息 I(xy)
- 互信息 I(x;y)
- 条件互信息 I(x;y|z)

2. 事件集的平均信息度量

- 熵 H(X)
- 条件熵 H(Y|X)
- 联合熵 H(XY)
- 平均互信息 I(X;Y)
- 平均条件互信息 I(X;Y|Z)

二、符号约定（概率论基础）

- 小写字母 x, y：表示随机事件
- 大写字母 X, Y：表示随机变量
- $P(a_i)$：事件 $x=a_i$ 发生的概率
- $P(a_i, b_j)$：联合概率 $P(x=a_i, y=b_j)$
- $P(a_i|b_j)$：条件概率 $P(x=a_i \mid y=b_j)$

三、自信息与互信息（离散）

3.1 自信息 I(x)

定义：事件 $x=a_i$ 的自信息量为

$I(a_i) = -\log P(a_i)$

简记：$I(x) = -\log p(x)$

关键性质：

1. $p(x) \in [0,1]$，且 $\Sigma p_i = 1$（归一性）
2. 对数底数 > 1 ⇒ $I(x) \geq 0$（非负性）
3. $I(x)$ 是 $p(x)$ 的单调递减函数：概率越小，信息量越大

单位选择：

- 以 2 为底：比特（bit）★最常用
- 以 e 为底：奈特（nat），1 nat ≈ 1.443 bit
- 以 10 为底：哈特（Hartley），1 Hart ≈ 3.322 bit

物理含义（双重理解）：

- 事件发生前：表示该事件发生的**不确定性大小**
- 事件发生后：表示该事件发生时**带来的信息量大小**
- 等价理解：确定事件是否发生所需的二进制位数（以2为底时）

3.2 联合自信息 I(xy)

定义：联合事件 $(x=a_i, y=b_j)$ 的自信息量为

$I(a_i, b_j) = -\log P(a_i, b_j)$

简记：$I(xy) = -\log p(xy)$

关键说明：

- 联合概率 $p(xy)$ 需满足非负性与归一性：$\Sigma_x \Sigma_\gamma p(xy) = 1$
- 可将 (x,y) 视为单一复合事件，其含义与自信息完全一致

含义：

- 多个事件同时发生的**不确定性**
- 多个事件同时发生时**带来的总信息量**
- 表示该联合信息所需的二进制位数

3.3 条件自信息 I(x|y)

定义：在事件 $y=b_j$ 发生的条件下，事件 $x=a_i$ 的自信息量为

$I(a_i \mid b_j) = -\log P(a_i \mid b_j)$

简记：$I(x|y) = -\log p(x|y)$

关键说明：

- 条件概率 $p(x|y)$ 需满足：对固定 y，$\Sigma_x p(x|y) = 1$

- 可将 "x|y" 视为单一事件，含义与自信息一致

三重含义：

1. 已知 y 发生后，x 仍保留的**不确定性**
2. y 发生后，x 再发生所**新增的信息量**
3. 在 y 已知前提下，确认 x 是否发生所需的信息量

三者关系（核心公式）：
$I(xy) = I(x) + I(y|x) = I(y) + I(x|y)$

3.4 互信息 I(x;y)

定义：两个离散事件 x, y 之间的互信息为
$I(x;y) = \log [p(x|y) / p(x)] = \log [p(xy) / (p(x)p(y))]$
等价形式：$I(x;y) = I(x) - I(x|y)$

核心含义：
互信息 = 原有不确定性 − 尚存不确定性
即：y 的出现所**消除的**关于 x 的不确定性，或 y 所提供的关于 x 的信息量。

关键性质：

1. **互易性**：$I(x;y) = I(y;x)$
   → y 提供关于 x 的信息量 = x 提供关于 y 的信息量
2. **独立性判据**：若 x, y 统计独立 ⇒ $p(x|y)=p(x)$ ⇒ $I(x;y)=0$
   → 独立事件间无信息增益
3. **可正可负**：
   - $I(x;y) > 0$：y 的出现**支持**x 发生（如：乌云→降雨）
   - $I(x;y) < 0$：y 的出现**否定**x 发生（如：从未上课→考满分）
4. **有界性**：$I(x;y) \le \min\{ I(x), I(y) \}$
   → 互信息不可能超过任一事件的自信息

物理意义（通信视角）：
信道输出端收到 y 后，获得的关于输入端消息 x 的信息量。互信息的引入使信息传输问题进入**定量分析**范畴，是信息论发展的里程碑。

3.5 条件互信息 $I(x;y|z)$

定义：在给定 $z \in Z$ 条件下，$x \in X$ 与 $y \in Y$ 之间的互信息为

$I(x;y|z) = \log [p(x|y,z) / p(x|z)]$

说明：

- 除增加条件 z 外，其含义、性质与普通互信息完全一致
- 可理解为：在已知 z 的前提下，y 对 x 的**额外信息增益**

四、信息熵的基本概念（离散）

4.1 信息熵 $H(X)$

定义：离散信源 $X = \{x_1, x_2, ..., x_n\}$，概率分布 $P = [p(x_1), ..., p(x_n)]$，其熵为自信息的期望：

$H(X) = E[I(x)] = \Sigma_x p(x)\cdot I(x) = - \Sigma_x p(x)\cdot \log p(x)$

记作 $H(p_1, p_2, ..., p_n)$，单位：比特/符号（或奈特/符号）

四重含义（表征信源总体特性）：

1. 信源输出前：信源的**平均不确定性**
2. 信源输出后：一个符号所提供的**平均信息量**
3. 随机性度量：H(X) 越大，信源随机性越强
4. 编码视角：解除信源不确定性所需的**平均最小信息量**

4.2 条件熵 $H(Y|X)$

定义：联合集 XY 上，条件自信息 $I(y|x)$ 的期望：

$H(Y|X) = E[I(y|x)] = - \Sigma_x \Sigma_\gamma p(x,y)\cdot \log p(y|x)$

等价形式：$H(Y|X) = \Sigma_x p(x)\cdot H(Y|x)$

其中 $H(Y|x) = - \Sigma_\gamma p(y|x)\cdot \log p(y|x)$ 为给定 X=x 时 Y 的熵

含义：已知 X 后，Y 仍保留的**平均不确定性**

4.3 联合熵 H(XY)

定义：联合集 XY 上，联合自信息 I(xy) 的期望：

$$H(XY) = E[I(xy)] = - \Sigma_x \Sigma_\gamma p(x,y) \cdot \log p(x,y)$$

含义：X 与 Y 作为整体时的**总平均不确定性**

4.4 相对熵 / 信息散度 D(P‖Q)

定义：同一字母表上两个概率分布 P(x) 与 Q(x) 之间的"距离"：

$$D(P\|Q) = \Sigma_x P(x) \cdot \log [P(x) / Q(x)]$$

关键性质：

- $D(P\|Q) \geq 0$（Gibbs 不等式），等号成立 $\Leftrightarrow P(x) = Q(x), \forall x$
- **非对称**：$D(P\|Q) \neq D(Q\|P)$，不是严格意义上的距离
- 衡量用 Q 近似 P 时的**信息损失**

4.5 交叉熵 H(P, Q)

定义：真实分布 P，预测分布 Q，则交叉熵为

$$H(P, Q) = - \Sigma_i p_i \cdot \log q_i$$

与散度关系：

$$D(P\|Q) = H(P, Q) - H(P)$$

⇒ 当 $Q \to P$ 时，$D(P\|Q) \to 0$，交叉熵 → 信息熵

应用价值：
交叉熵越小 ⇒ 预测分布 Q 越接近真实分布 P
→ 深度学习中广泛用作分类任务的**损失函数**

4.6 各类熵的关系图谱

```
        H(XY)
       /     \
   H(X)       H(Y)
      \       /
     I(X;Y)  ← 平均互信息（重叠部分）
      /       \
 H(X|Y)       H(Y|X)
```

核心恒等式:

1. $H(XY) = H(X) + H(Y|X) = H(Y) + H(X|Y)$ （链式分解）
2. $I(X;Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$
3. $I(X;Y) = H(X) + H(Y) - H(XY)$

熵的不增原理:
$H(Y|X) \le H(Y)$
→ 条件越多，不确定性越小（信息处理中"知识消除不确定性"）

五、信息熵的基本性质（离散）

5.1 基础性质

1. **对称性**: $H(p_1, p_2, ..., p_n)$ 中各 p_i 次序可任意交换，熵值不变
2. **非负性**: $H(X) \ge 0$（因 $I(x) \ge 0$，期望非负）
3. **确定性**: 若某事件概率为 1（其余为 0），则 $H = 0$
   → 确定事件无不确定性，不提供信息

5.2 结构性质

4. **可加性（链原则）**:
   $H(X_1X_2...X_n) = H(X_1) + H(X_2|X_1) + ... + H(X_n|X_1...X_{n-1})$
   → 复合事件的不确定性 = 各阶段条件不确定性的累加
5. **扩展性**:
   $\lim_{\varepsilon\to0} H(p_1, ..., p_{n-1}, p_n-\varepsilon, \varepsilon) = H(p_1, ..., p_n)$
   → 极小概率事件对熵的贡献可忽略

5.3 极值与凸性

6. **极值性（最大熵定理）**：
   对 n 元离散信源，$H(X) \le \log n$，等号成立 $\Leftrightarrow p_i = 1/n$（等概分布）
   → **等概率时不确定性最大**，是信源编码的理论上限
7. **上凸性**：
   $H(p_1, ..., p_n)$ 是概率矢量 $(p_1, ..., p_n)$ 的**严格上凸函数**
   → 混合分布的熵 ≥ 各成分熵的加权平均（Jensen 不等式应用）

5.4 变换不变性

8. **一一对应变换下的不变性**：
   若 $Y = f(X)$ 为一一映射 $\Rightarrow H(Y) = H(X)$
   若 f 非一一映射（多对一） $\Rightarrow H(Y) \le H(X)$
   → 信息不会因确定性变换而增加

5.5 熵函数的唯一性定理

若函数 H 满足以下三条公理，则其形式必为 $H = -\Sigma\, p_i \log p_i$：

1. H 是概率的连续函数
2. 等概时，H 是符号数 n 的单调增函数
3. 满足可加性（链原则）

六、平均互信息（离散）

6.1 定义与计算

层级定义：

1. 事件 x 与集合 Y 的平均互信息：
   $I(x;Y) = \Sigma_\gamma\, p(y|x)\cdot\log [\, p(y|x)/p(y) \,] \ge 0$
2. 集合 X 与 Y 的平均互信息：
   $I(X;Y) = \Sigma_x\, p(x)\cdot I(x;Y) = \Sigma_x\, \Sigma_\gamma\, p(x,y)\cdot\log [\, p(x,y)/(p(x)p(y)) \,]$

三种等价表达（核心公式）：

- $I(X;Y) = H(X) - H(X|Y)$
- $I(X;Y) = H(Y) - H(Y|X)$

- $I(X;Y) = H(X) + H(Y) - H(XY)$

含义：

- Y 中一个事件平均能**消除**的关于 X 的不确定性
- X 与 Y 之间**统计关联程度**的度量
- 通信中：接收端平均获得的关于发送端消息的信息量

6.2 平均互信息的性质

1. **非负性**：$I(X;Y) \geq 0$，等号 $\Leftrightarrow$ X, Y 独立
   → 观测不会减少平均信息量（与条件互信息非负性呼应）
2. **互易性（对称性）**：$I(X;Y) = I(Y;X)$
3. **凸函数性**（优化理论基础）：
   - 固定信道 $p(y|x)$：$I(X;Y)$ 是输入分布 $p(x)$ 的**上凸函数**
     → 存在唯一最大互信息（信道容量）
   - 固定输入 $p(x)$：$I(X;Y)$ 是信道转移概率 $p(y|x)$ 的**下凸函数**
4. **极值性（有界性）**：
   $I(X;Y) \leq \min\{ H(X), H(Y) \}$
   → 平均互信息不超过任一信源的熵

6.3 平均条件互信息 $I(X;Y|Z)$

定义：
$I(X;Y|Z) = \Sigma_{x,y,z} p(x,y,z) \cdot \log [p(x|y,z) / p(x|z)]$

关键性质：

1. **非负性**：$I(X;Y|Z) \geq 0$，等号 $\Leftrightarrow$ $p(x|y,z) = p(x|z)$（给定 Z 时 $X \perp Y$）
2. **链式分解**：
   $I(X;YZ) = I(X;Z) + I(X;Y|Z) = I(X;Y) + I(X;Z|Y)$
3. **信息细化原理**：
   - 合并事件 $\Rightarrow$ 信息量减少（边缘化损失信息）
   - 细化取值空间 $\Rightarrow$ 信息量增加（条件化增益信息）
     → 为特征工程、变量选择提供理论依据

6.4 平均互信息的链原则

定理：
$I(X_1X_2...X_n; Y) = \Sigma_{i=1}^n I(X_i; Y | X_1...X_{i-1})$

意义：
多变量联合提供的信息量 = 各变量在已知前序变量条件下的**增量信息**之和
→ 是特征选择、逐步回归、信息瓶颈等方法的理论基础

七、核心公式速查表

概念	公式	关键说明
自信息	$I(x) = -\log p(x)$	概率越小，信息量越大
联合自信息	$I(xy) = -\log p(xy)$	可分解：$I(xy)=I(x)+I(y\|x)$
条件自信息	$I(x\|y) = -\log p(x\|y)$	已知 y 后 x 的剩余不确定性
互信息	$I(x;y) = \log[p(x\|y)/p(x)] = I(x)-I(x\|y)$	y 消除的 x 的不确定性
熵	$H(X) = -\Sigma\, p(x)\log p(x)$	平均不确定性，等概时最大
条件熵	$H(Y\|X) = -\Sigma\, p(x,y)\log p(y\|x)$	已知 X 后 Y 的平均不确定性
联合熵	$H(XY) = -\Sigma\, p(x,y)\log p(x,y)$	X,Y 整体的不确定性
平均互信息	$I(X;Y) = H(X)-H(X\|Y)$	X,Y 之间的平均信息共享量
信息散度	$D(P\|Q) = \Sigma\, P \log(P/Q) \geq 0$	P 与 Q 的"距离"，非对称
交叉熵	$H(P,Q) = -\Sigma\, p \log q$	预测分布 Q 对真实 P 的编码代价

八、学习要点总结

1. **信息 = 不确定性的减少**：所有度量均围绕"概率→不确定性→信息量"主线展开
2. **对数函数的核心作用**：满足可加性（独立事件信息量相加）、单调性（概率与信息量反向）
3. **期望是连接单事件与集合的桥梁**：熵 = 自信息的期望，平均互信息 = 互信息的期望
4. **凸性是优化的理论基础**：最大熵原理、信道容量求解均依赖熵与互信息的凸性
5. **条件化是信息增益的关键**：$H(Y|X) \leq H(Y)$，$I(X;Y|Z) \geq 0$ 体现"知识消除不确定性"

> 注：本笔记严格依据课件知识框架整理，适用于快速回顾核心定义、性质与公式体系。建议结合例题理解公式应用，通过推导掌握性质证明逻辑。