数据科学理论基础：机器学习

北京邮电大学

智能感知与计算教研中心

数据科学中心

什么是机器学习

- 机器学习基本概念

机器学习，即Machine Learning(简称ML)的直译。专门研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构使之不断改善自身的性能。

机器学习是人工智能的核心，是使计算机具有智能的根本途径，其应用遍及人工智能的各个领域。

相对于传统的计算机工作，我们给它一串指令，然后它遵照这个指令一步步执行下去即可。机器学习不是接受输入的指令，相反，它接受的是数据！也就是说它某种意义上具有了我们人处理事情的能力。

机器学习涉及概率论、统计学、逼近论、凸分析、算法复杂度理论等多门学科。

机器学习主要类型

- 监督学习
  - 训练数据已经被标签为一种合适的“输出”，对训练数据形成合适的模型。
  - 模型可以用来对不可见（没有打标签）数据进行预测

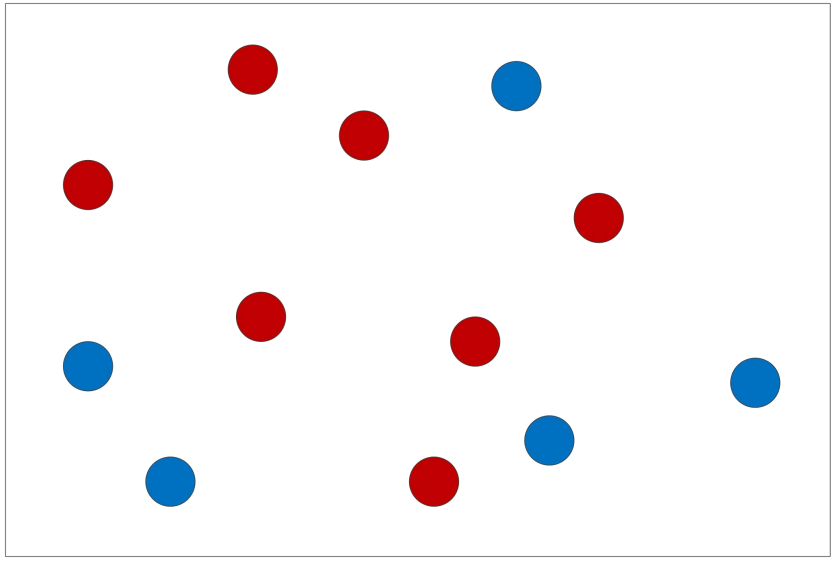

- 无监督学习
  - 无监督学习掌握数据中隐含的模式或规则
  - 例如“聚类”问题，共同特征的划分或者抽取其中的关联规则

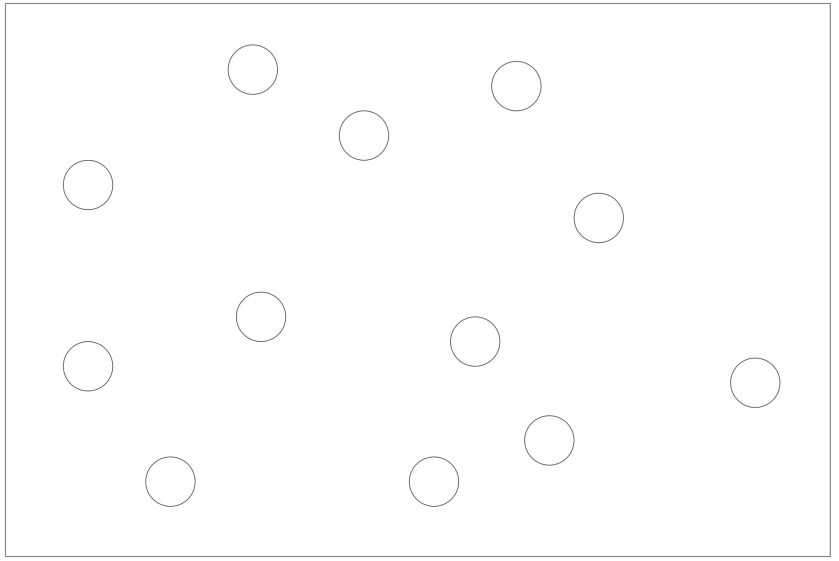

数据（Data）角度看传统机器学习任务

- 分类
  - 二元分类（C=2），将数据分离成可以区别的两组
  - 多元分类（C>2），二元分类的一般化
- 回归
  - 包含将数据项映射为实值
- 聚类
  - 依照数据基本特征将数据分成不同的簇（或概念，Concepts）
- 协同过滤（Collaborative Filtering）
  - 识别数据内部的规则或者关联，常用来进行商品推荐
- 降维（维数约减，Dimensionality Reduction）
  - 数据压缩、可视化数据

分类问题示例

分类问题的定义

已知一批样本$\{(\boldsymbol{x}_i, y_i), i = 1, \cdots, n\}$，其中$\boldsymbol{x}_i \in R^d$，$y_i \in \{1, \cdots, k\}$， k为不同类别的个数。称$\boldsymbol{x}$为样本的属性/特征向量， y为样本的标签值。

通过训练样本得到最优分类器：$y = \hat{f}(\boldsymbol{x})$，建立以分类器为核心的分类系统，预测已知属性未知标签的新样本$\boldsymbol{x}_{n+1}$。

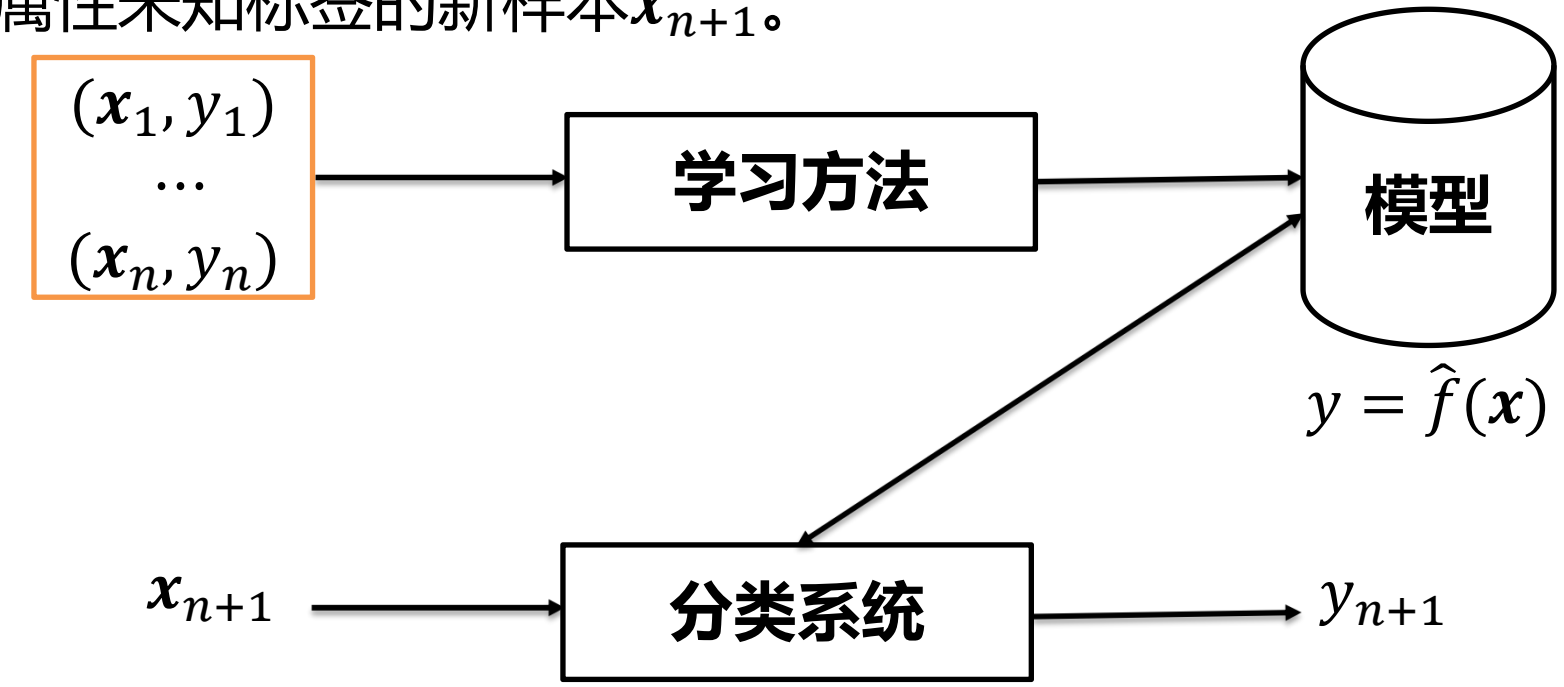

分类器的“三项基本原则”

Training data:

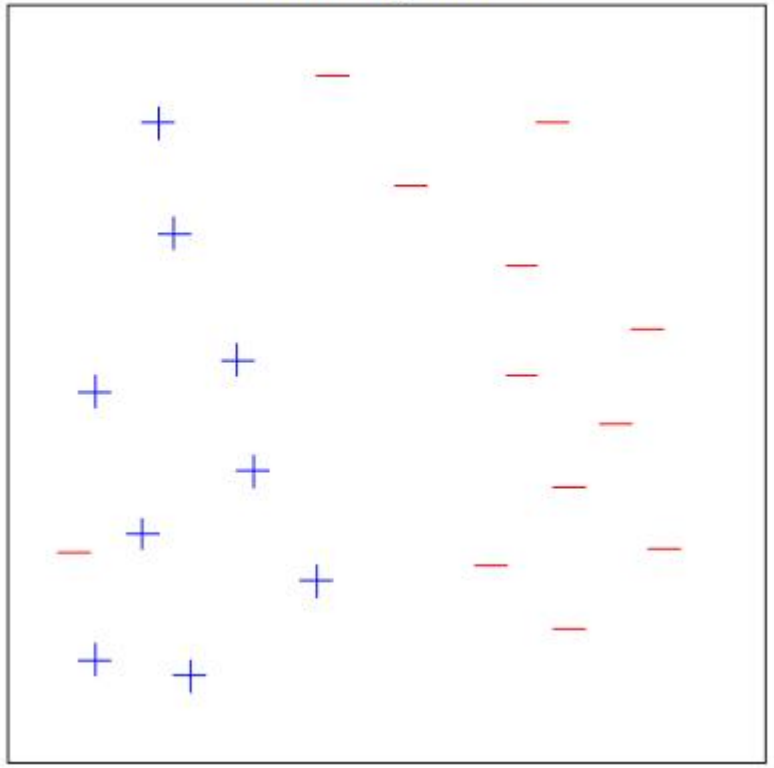

Bad:

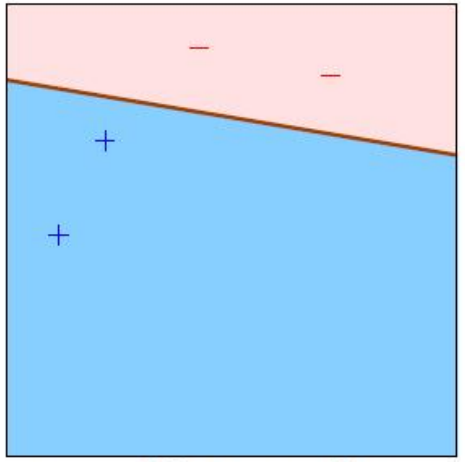

insufficient data

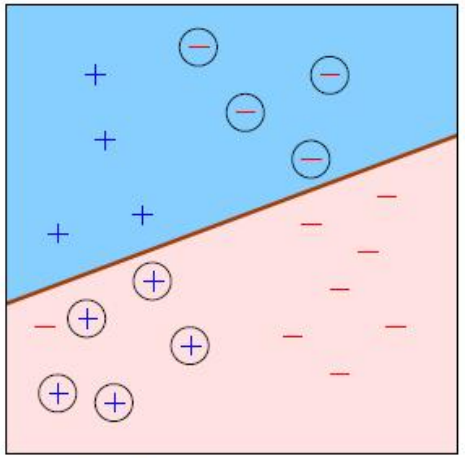

training error
too high

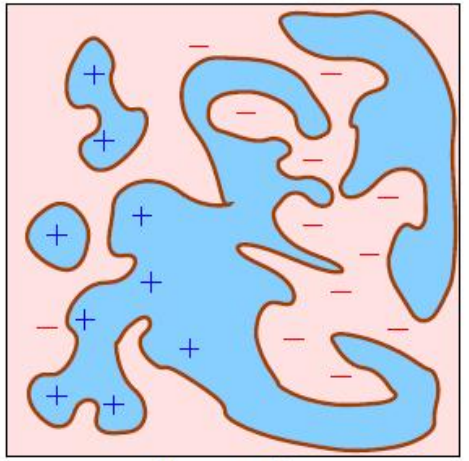

classifier
too complex

Good:

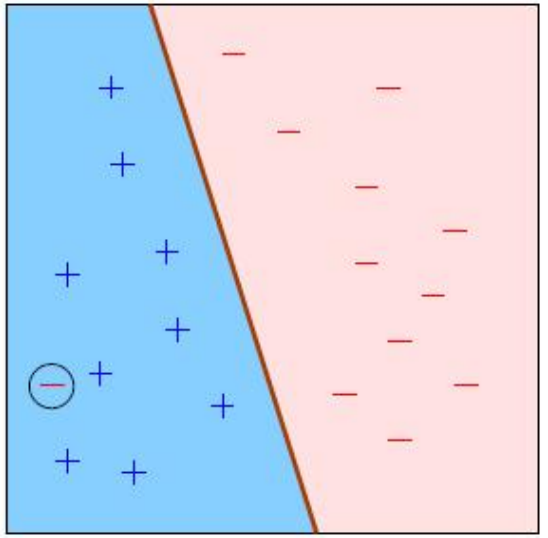

sufficient data
low training error
simple classifier

分类

- 机器学习分类算法
- 分类评估方法

机器学习分类算法

- KNN临近算法
- 决策树
- 贝叶斯分类算法
- 支持向量机SVM

KNN临近算法

- 简单的分类算法

K最近邻(K-Nearest Neighbor,KNN)算法：最简单的机器学习算法之一，也是基于实例的学习方法中最基本的、最好的文本分类算法之一。

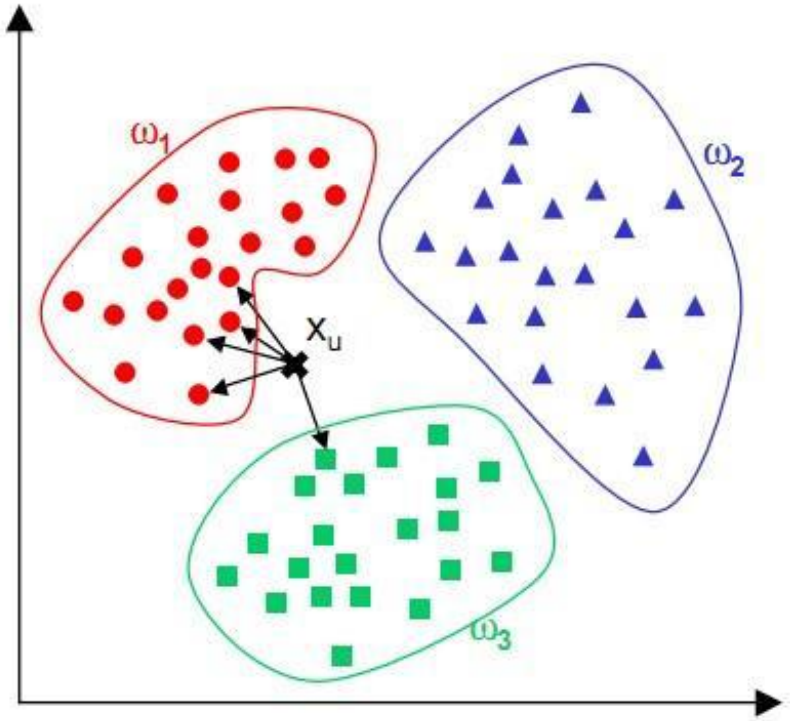

基本思想：

一个样本x与样本集中的k个最相邻的样本中的大多数属于某一个类别yLabel，那么该样本x也属于类别yLabel，并具有这个类别样本的特性。

简而言之，一个样本与数据集中的k个最相邻样本中的大多数的类别相同。

KNN临近算法

- 算法流程

1. 确定训练数据及其对应的类别标签。
2. 计算待分类的测试数据与各个训练数据之间的距离。
3. 对距离从小到大进行排序。
4. 设定参数k，从训练集中挑选出最相近的k个数据。
5. 确定前k个数据相应类别出现的频率。
6. 少数服从多数原则，将出现频率最高的类别作为预测进行分类。

KNN算法的优缺点

- 优点

（1）理论成熟简单，易于理解及算法实现；

（2）适合对稀有事件进行分类；

（3）特别适合于多分类问题(multi-modal,对象具有多个类别标签)。

- 缺点

（1）需要计算待分类样本与所有已知样本的距离，计算量大；

（2）样本容量小或样本分布不均衡时，容易分类错误，后者可通过施加距离权重进行改善。

机器学习分类算法

- KNN临近算法
- 决策树
- 贝叶斯分类算法
- 支持向量机SVM

决策树（Decision Tree, DT）

- *女儿：多大年纪了？*
- *母亲：26。*
- *女儿：长的帅不帅？*
- *母亲：挺帅的。*
- *女儿：收入高不？*
- *母亲：不算很高，中等情况。*
- *女儿：是公务员不？*
- *母亲：是，在税务局上班呢。*
- *女儿：那好，我去见见。*

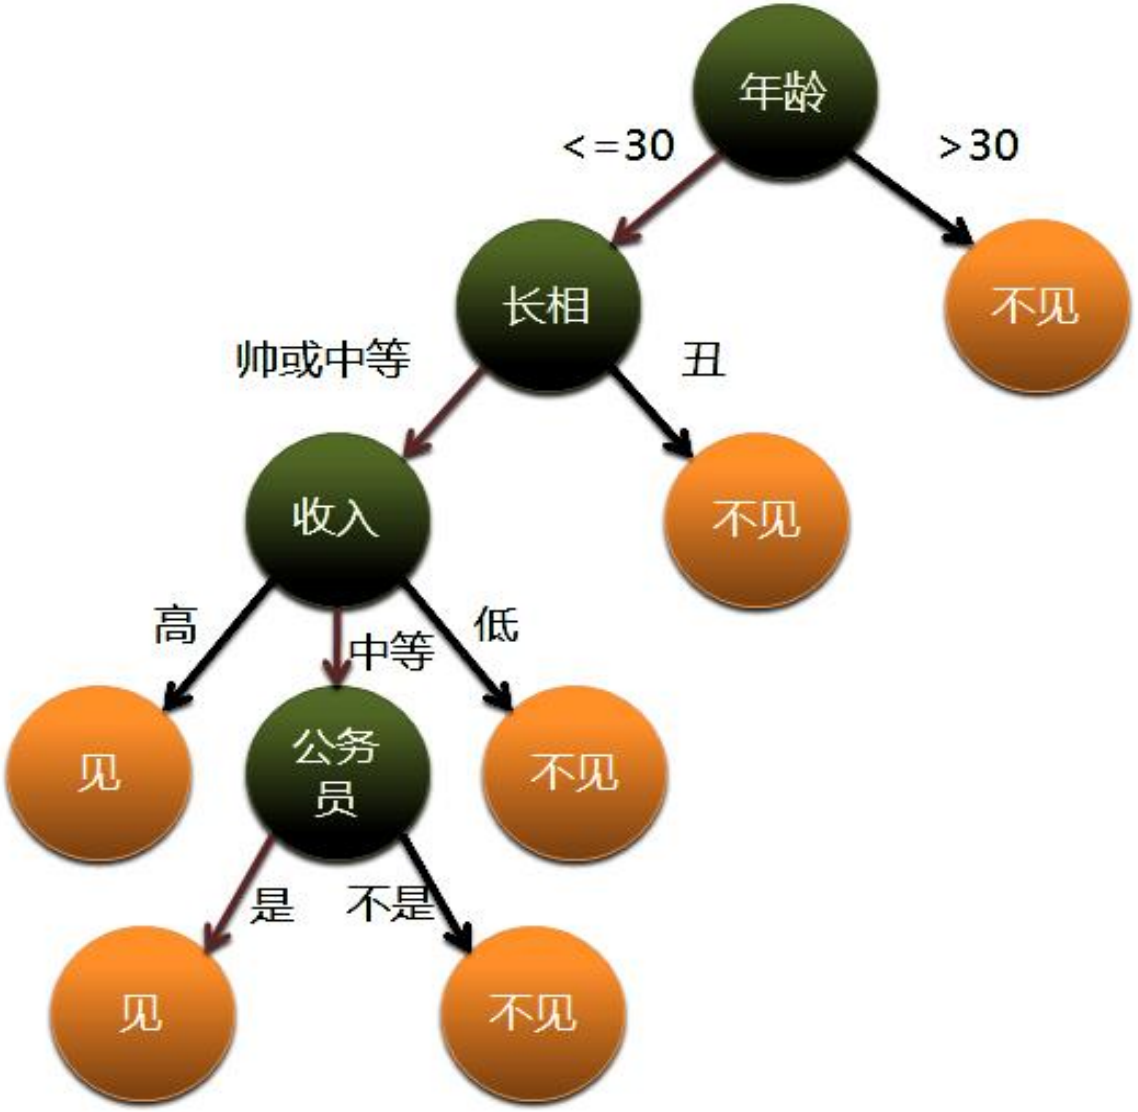

决策树

- 根据数据的属性建立树状结构决策模型，常用来解决分类和回归问题。
- 以实例为基础的归纳学习。
- 采用的是自顶向下的递归方法。
  - 以 ID3为例：其基本思想是以信息熵为度量构造一棵熵值下降最快的树。

信息熵

- 熵（Entropy）是无序性（或不确定性）的度量指标。
- 假如事件A的全概率划分是$(A_1, A_2, \cdots, A_n)$，每部分发生的概率是$(p_1, p_2, \cdots, p_n)$，信息熵定义为：

$$\mathrm{Ent}(p_1, p_2, \cdots, p_n) = -\sum_{i=1}^{n} p_i \log_2 (p_i)$$

- 信息熵用来衡量信息量的大小。
  - 若不确定性越大，则信息量越大，熵越大；
  - 若不确定性越小，则信息量越小，熵越小。
- 构造树的基本想法是随着树深度的增加，节点的熵迅速地降低。熵降低的速度越快越好，这样我们有望得到一棵高度最矮的决策树。

信息增益

信息增益定义为样本集合S按照某属性A划分时，造成熵的减少量。其计算公式为：

$$\mathrm{Gain}(S,A) = \mathrm{Ent}(S) - \sum_{v \in Val(A)} \frac{|S_v|}{|S|} \mathrm{Ent}(S_v)$$

- $Val(A)$是属性A的值域
- S_v为S中属性A取值等于v的样本集合
- $|\cdot|$为集合的基数

信息增益描述属性A区分训练样本S中不同类别样本的能力，使S 的不确定性减少的能力。

决策树（以ID3为例）训练步骤

构建决策树的基本过程如下：

① 把所有记录看作一个节点

② 遍历每个属性变量的各种分割方式，根据**信息增益**最大的准则，找到最优的属性作为树的分割点

③ 根据该属性的取值将根节点分割成若干个子节点N_1，N_2，…

④ 对各个子节点分别继续执行2-3步，直到每个节点足够**“纯”**为止

决策树例子

- 目的：用ID3算法对天气是否适合打球做出决策
- 类别：Play ball={YES,NO}
- 属性：
  - outlook = { sunny, overcast, rain }
  - temperature = {hot, mild, cool }
  - humidity = { high, normal }
  - wind = {weak, strong }
- 数据集S：2周时间采集的训练数据

决策树例子

Day	Outlook	Temperature	Humidity	Wind	Play ball
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

决策树例子（续）

设样本集合为S。 S中打球$(+)$次数为9，不打球$(-)$次数为5 ，记为$S=(9+,5-)$ 。此时的熵为：

$$Ent(S)=-\frac{9}{14}\log_2\frac{9}{14}-\frac{5}{14}\log_2\frac{5}{14}=0.940。$$

属性变量有4个：outlook、temperature、humidity、windy、分别记为A_1,A_2,A_3,A_4。需要决定哪个属性作树的根节点。

对每项指标分别统计：在不同的取值下打球$(+)$和不打球$(-)$的次数。

outlook			temperature			humidity			windy			play	
	yes	no		yes	no		yes	no		yes	no	yes	no
sunny	2	3	hot	2	2	high	3	4	weak	6	2	9	5
overcast	4	0	mild	4	2	normal	6	1	strong	3	3		
rainy	3	2	cool	3	1								

决策树例子（续）

outlook		
	yes	no
sunny	2	3
overcast	4	0
rainy	3	2

当选取属性outlook时，计算相应的信息增益。

outlook取值：sunny、overcast、rainy。分别有5、4、5个子样本。

则outlook取值为sunny、overcast、rainy的概率分别是5/14、4/14、5/14。

- outlook=sunny时，$S_{sunny} = (2+, 3-)$，$\mathrm{Ent}(S_{sunny}) = 0.971$；
- outlook=overcast时，$S_{overcast} = (4+, 0-)$，$\mathrm{Ent}(S_{overcast}) = 0$；
- outlook= rainy时，$S_{rainy} = (3+, 2-)$，$\mathrm{Ent}(S_{rainy}) = 0.971$。

从而计算得到关于属性outlook的信息增益为

$$\mathrm{Gain}(\mathrm{outlook}) = 0.940 - \frac{5}{14} \times 0.971 - \frac{4}{14} \times 0 - \frac{5}{14} \times 0.971 = 0.247。$$

决策树例子（续）

同理分别计算关于属性为temperature、humidity、windy的信息增益。

$\text{Gain (temperature)} = 0.029$，$\text{Gain(humidity)} = 0.152$，$\text{Gain(windy)} = 0.048$，而已经计算得到$\mathbf{Gain(outlook) = 0.247}$。

按照信息增益最大的准则，选取outlook作为分割属性，分割根节点S。

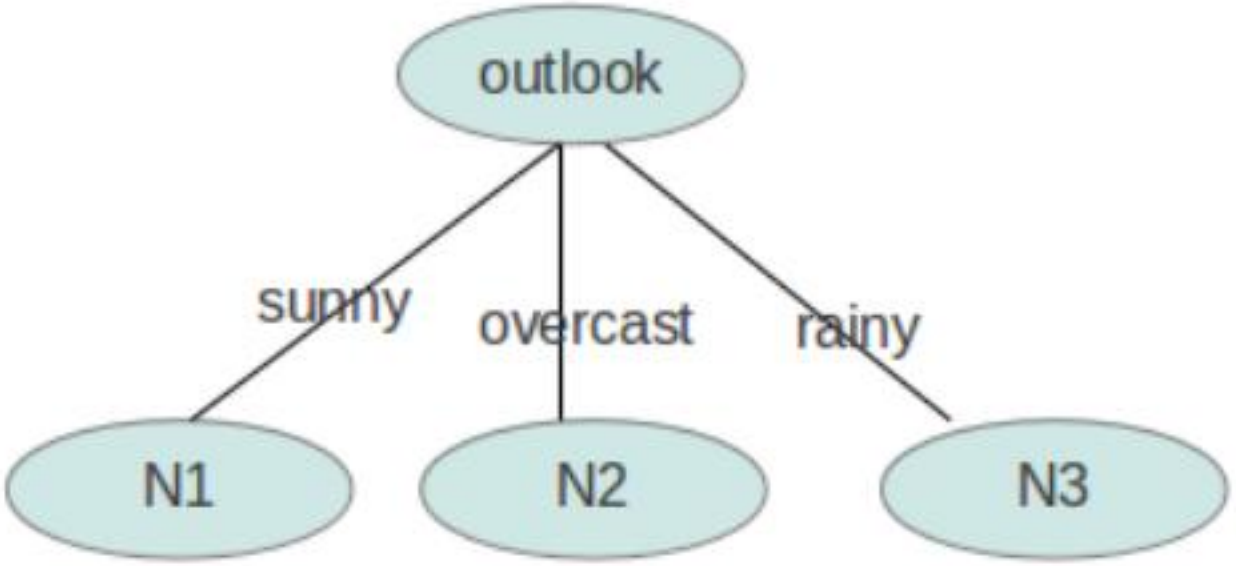

决策树例子（续）

- 根据outlook选择子集S_j
  - 在集合S中有5个样本的outlook是sunny，那么子集

$$S_{sunny} = \{D1, D2, D8, D9, D11\}$$

  - 按同样方法得到子集$S_{overcast}$， S_{rain}
- 计算各特征的信息增益
  - $Gain(S_{sunny}, Temperature) = 0.570$
  - $Gain(S_{sunny}, Humidity) = 0.970$
  - $Gain(S_{sunny}, Wind) = 0.019$

决策树例子（续）

分别对三个子节点N_1，N_2，N_3，递归调用建树算法，根据信息增益最大的准则，选择相应的分割属性，分裂成新的子节点，直至不能分裂，最终形成一棵决策树。

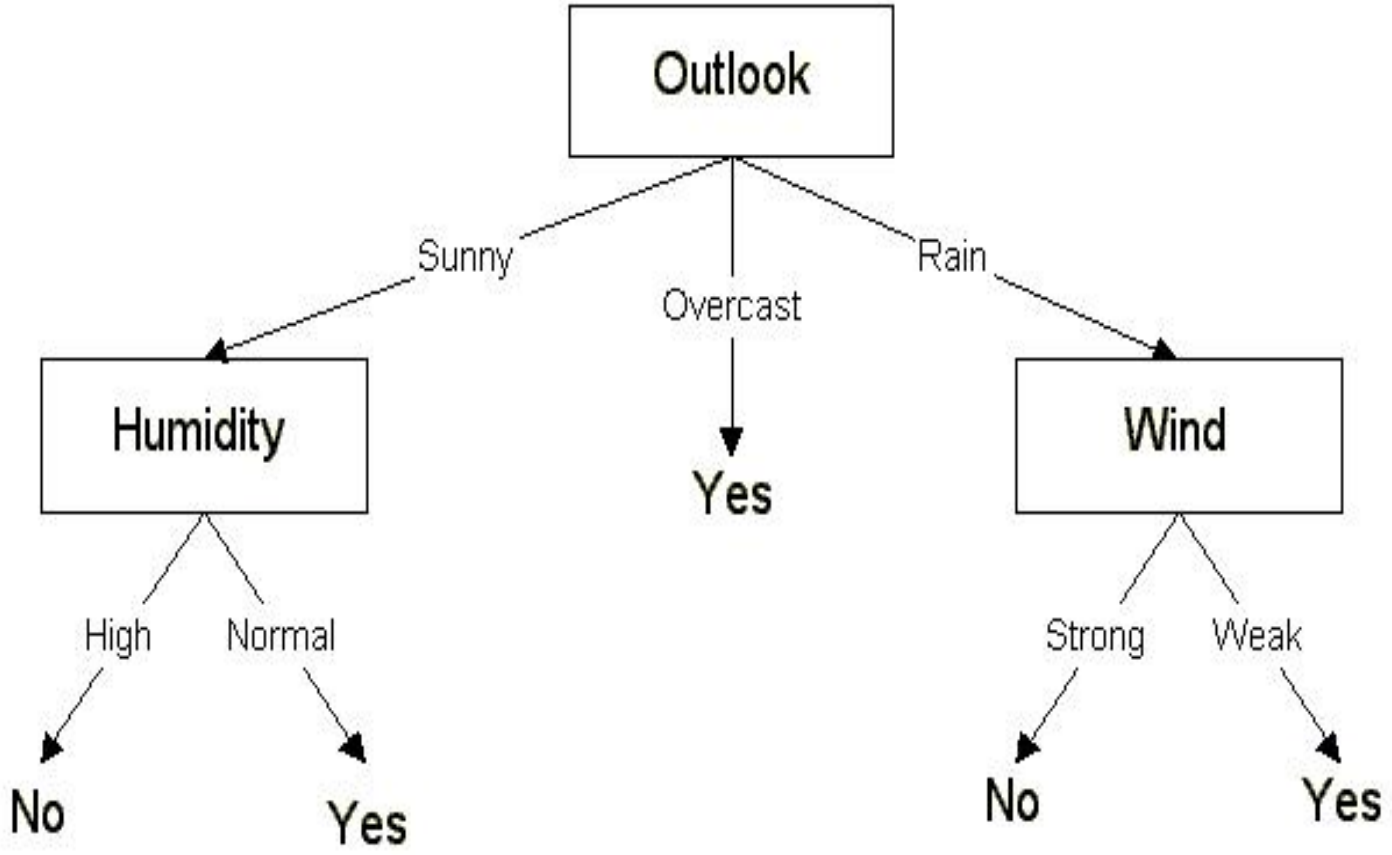

从决策树到随机森林（Random Forest， RF）

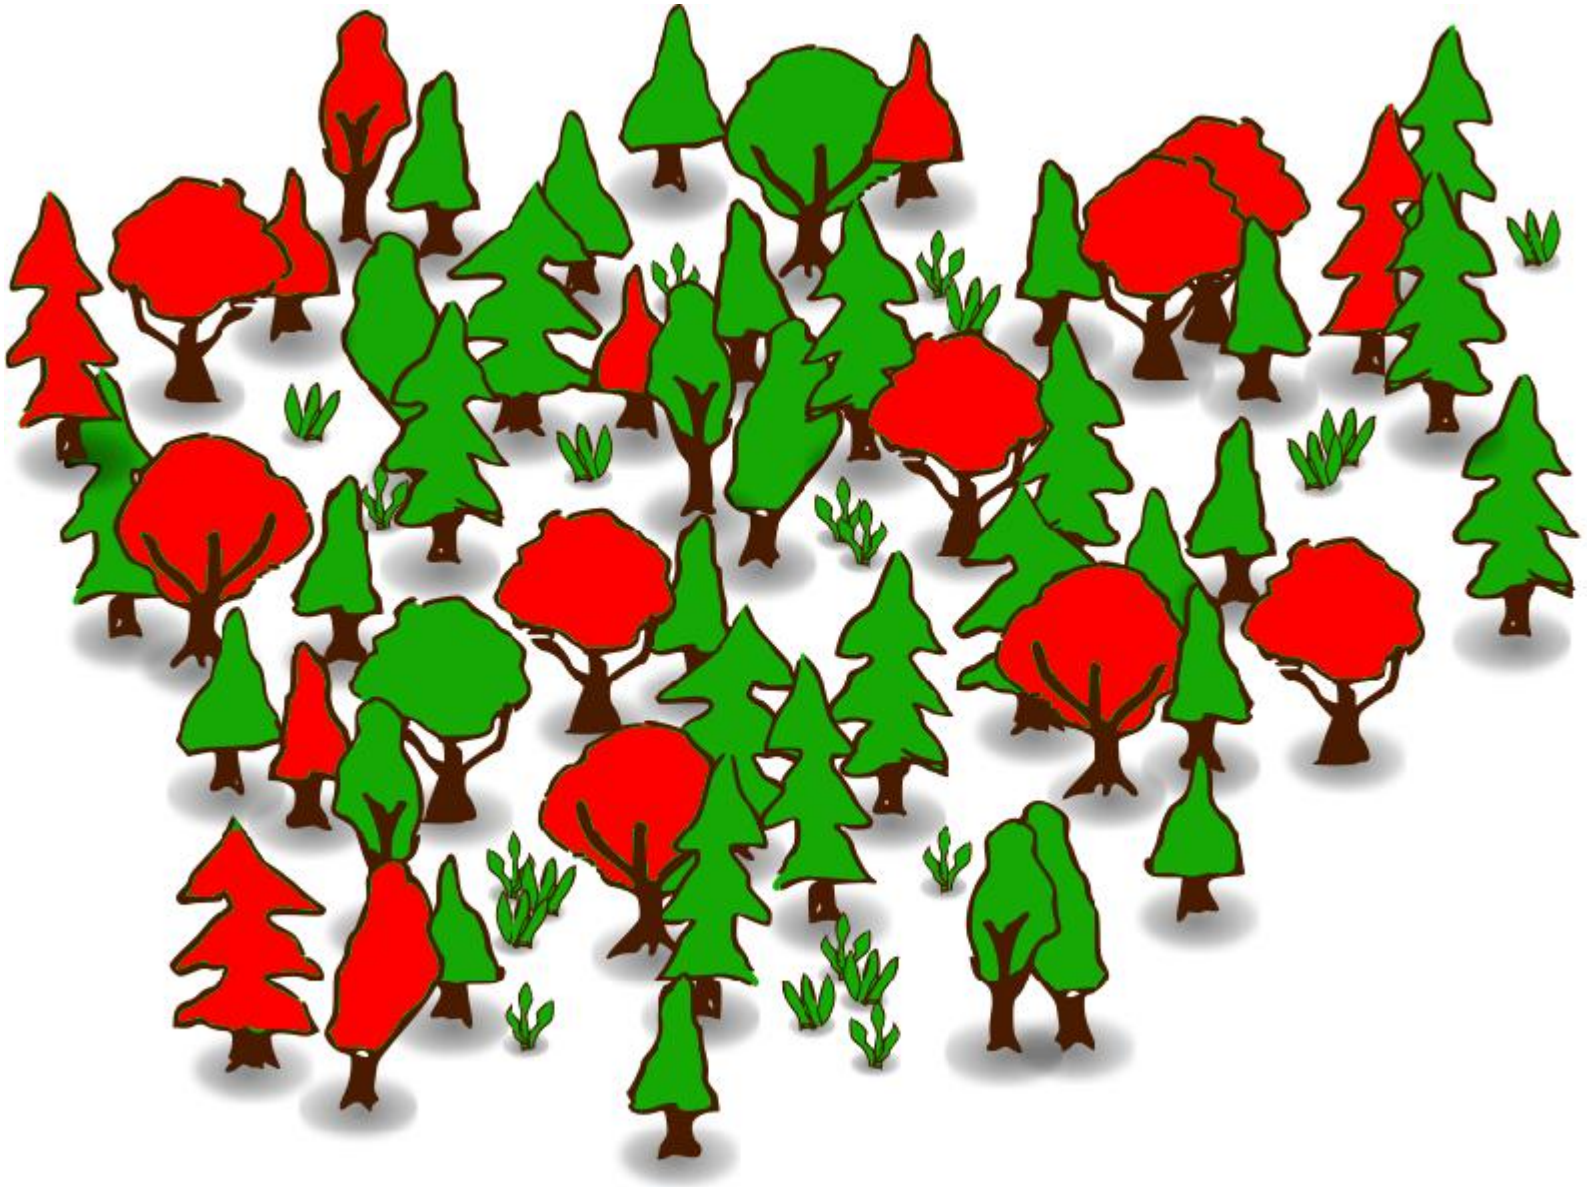

随机森林

- 随机森林是常用的集成学习算法。
- 集成算法用一些相对较弱的分类器，独立地就同一批的样本进行训练，然后把各自的学习结果按某种方式整合起来，进行预测。
- 集成算法的主要难点在于究竟集成哪些独立的较弱学习模型以及如何把学习结果整合起来。

集成学习示意图

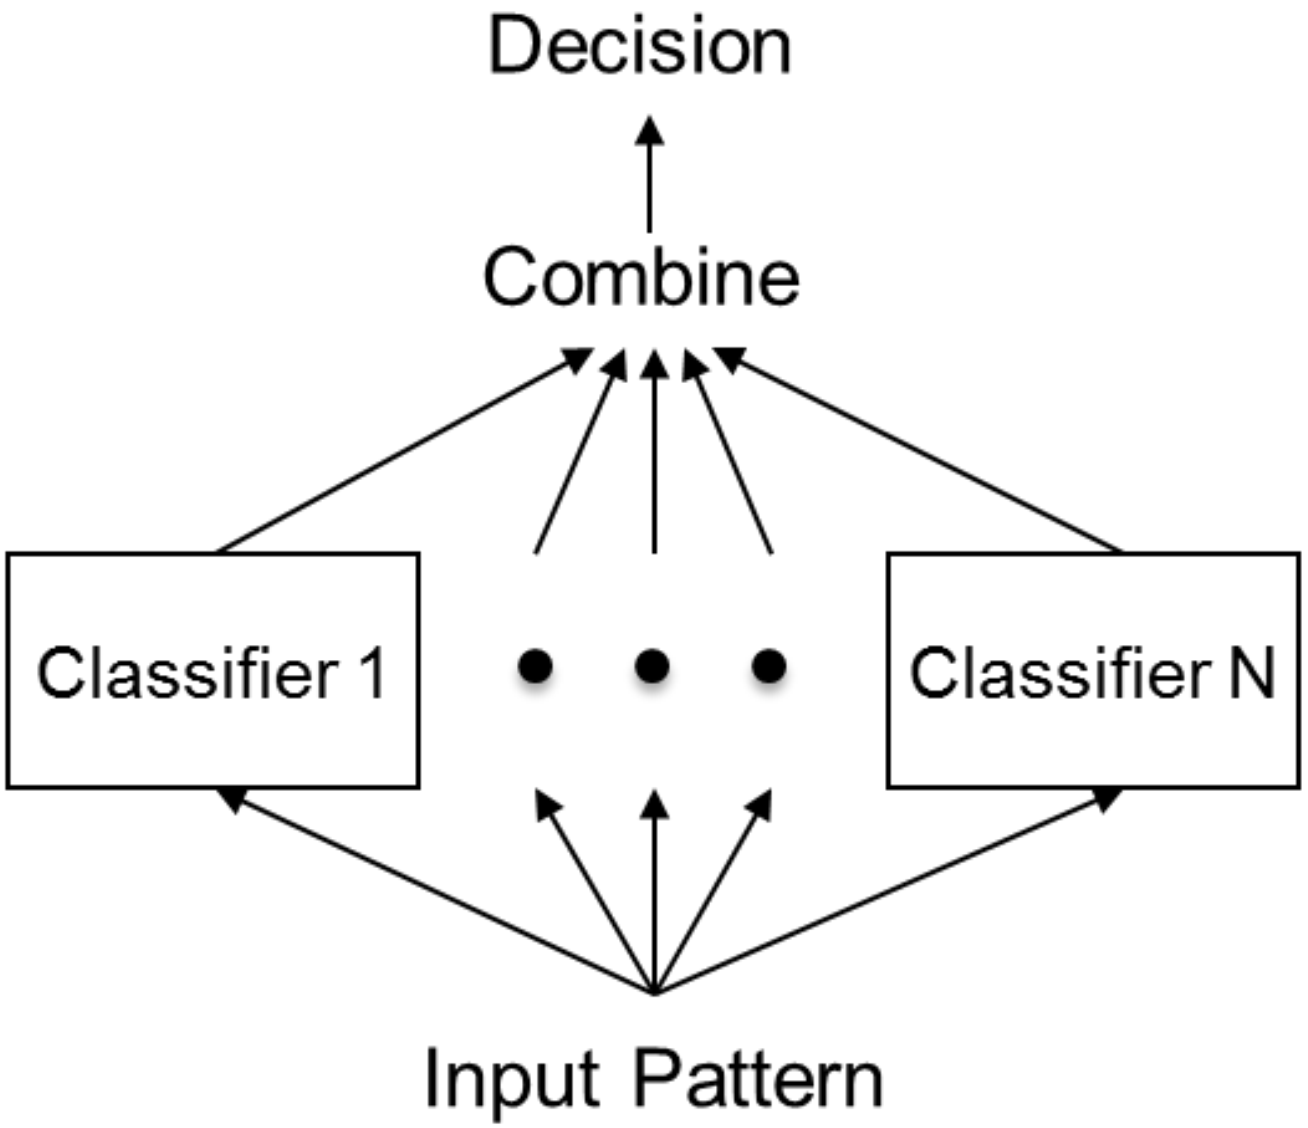

随机森林示意图

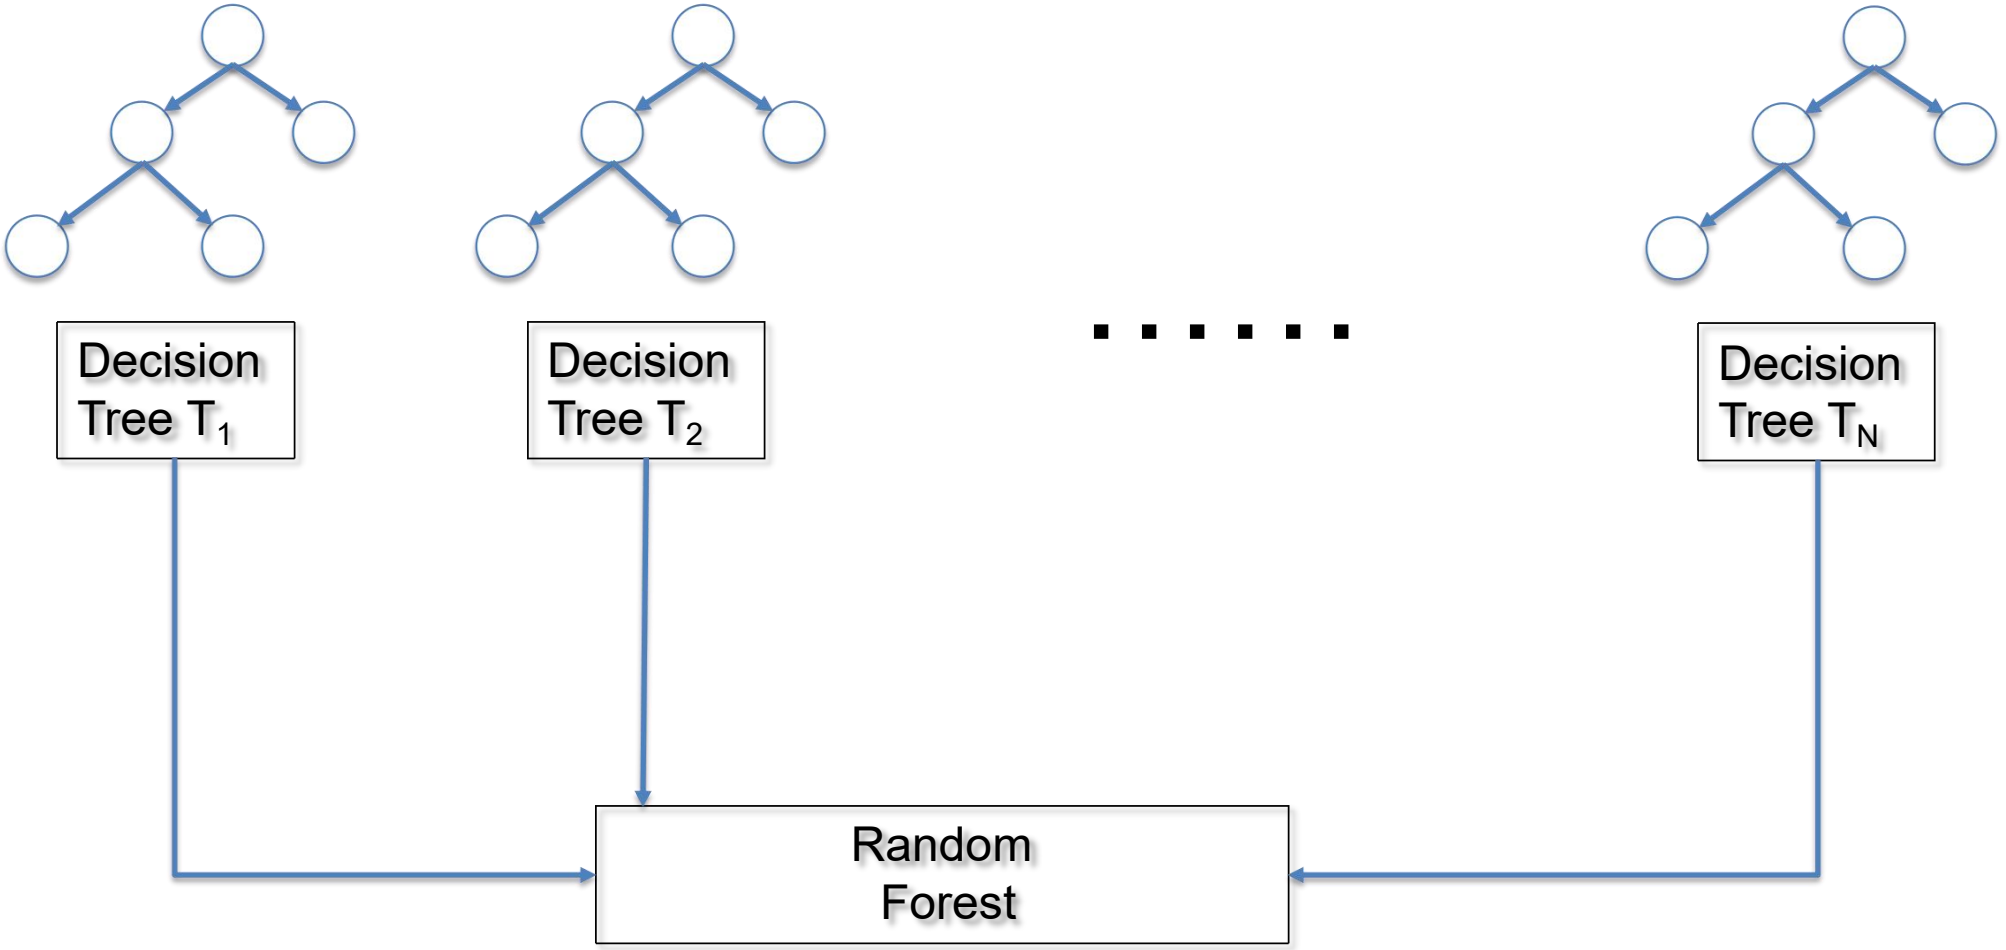
Decision Tree T_1
Decision Tree T_2
. . . . . .
Decision Tree T_N
Random Forest

随机森林训练步骤

随机森林的训练过程如下：

① 假如有N个样本，则有放回的随机选择n个样本。选择得到的n个样本作为决策树根节点，用来训练一个决策树。

② 设每个样本有d个属性。在决策树的每个节点需要分裂时，随机从d个属性中选取出m个属性，满足条件$m \ll d$。然后从这m个属性中采用某种信息论准则（比如说信息增益）来选择1个最优的属性作为该节点的分裂属性。

③ 决策树形成过程中每个节点都要按照步骤2来分裂。直到不能够再分裂为止。

④ 按照步骤1~3建立大量的决策树，这样就构成了随机森林。

随机森林训练流程图

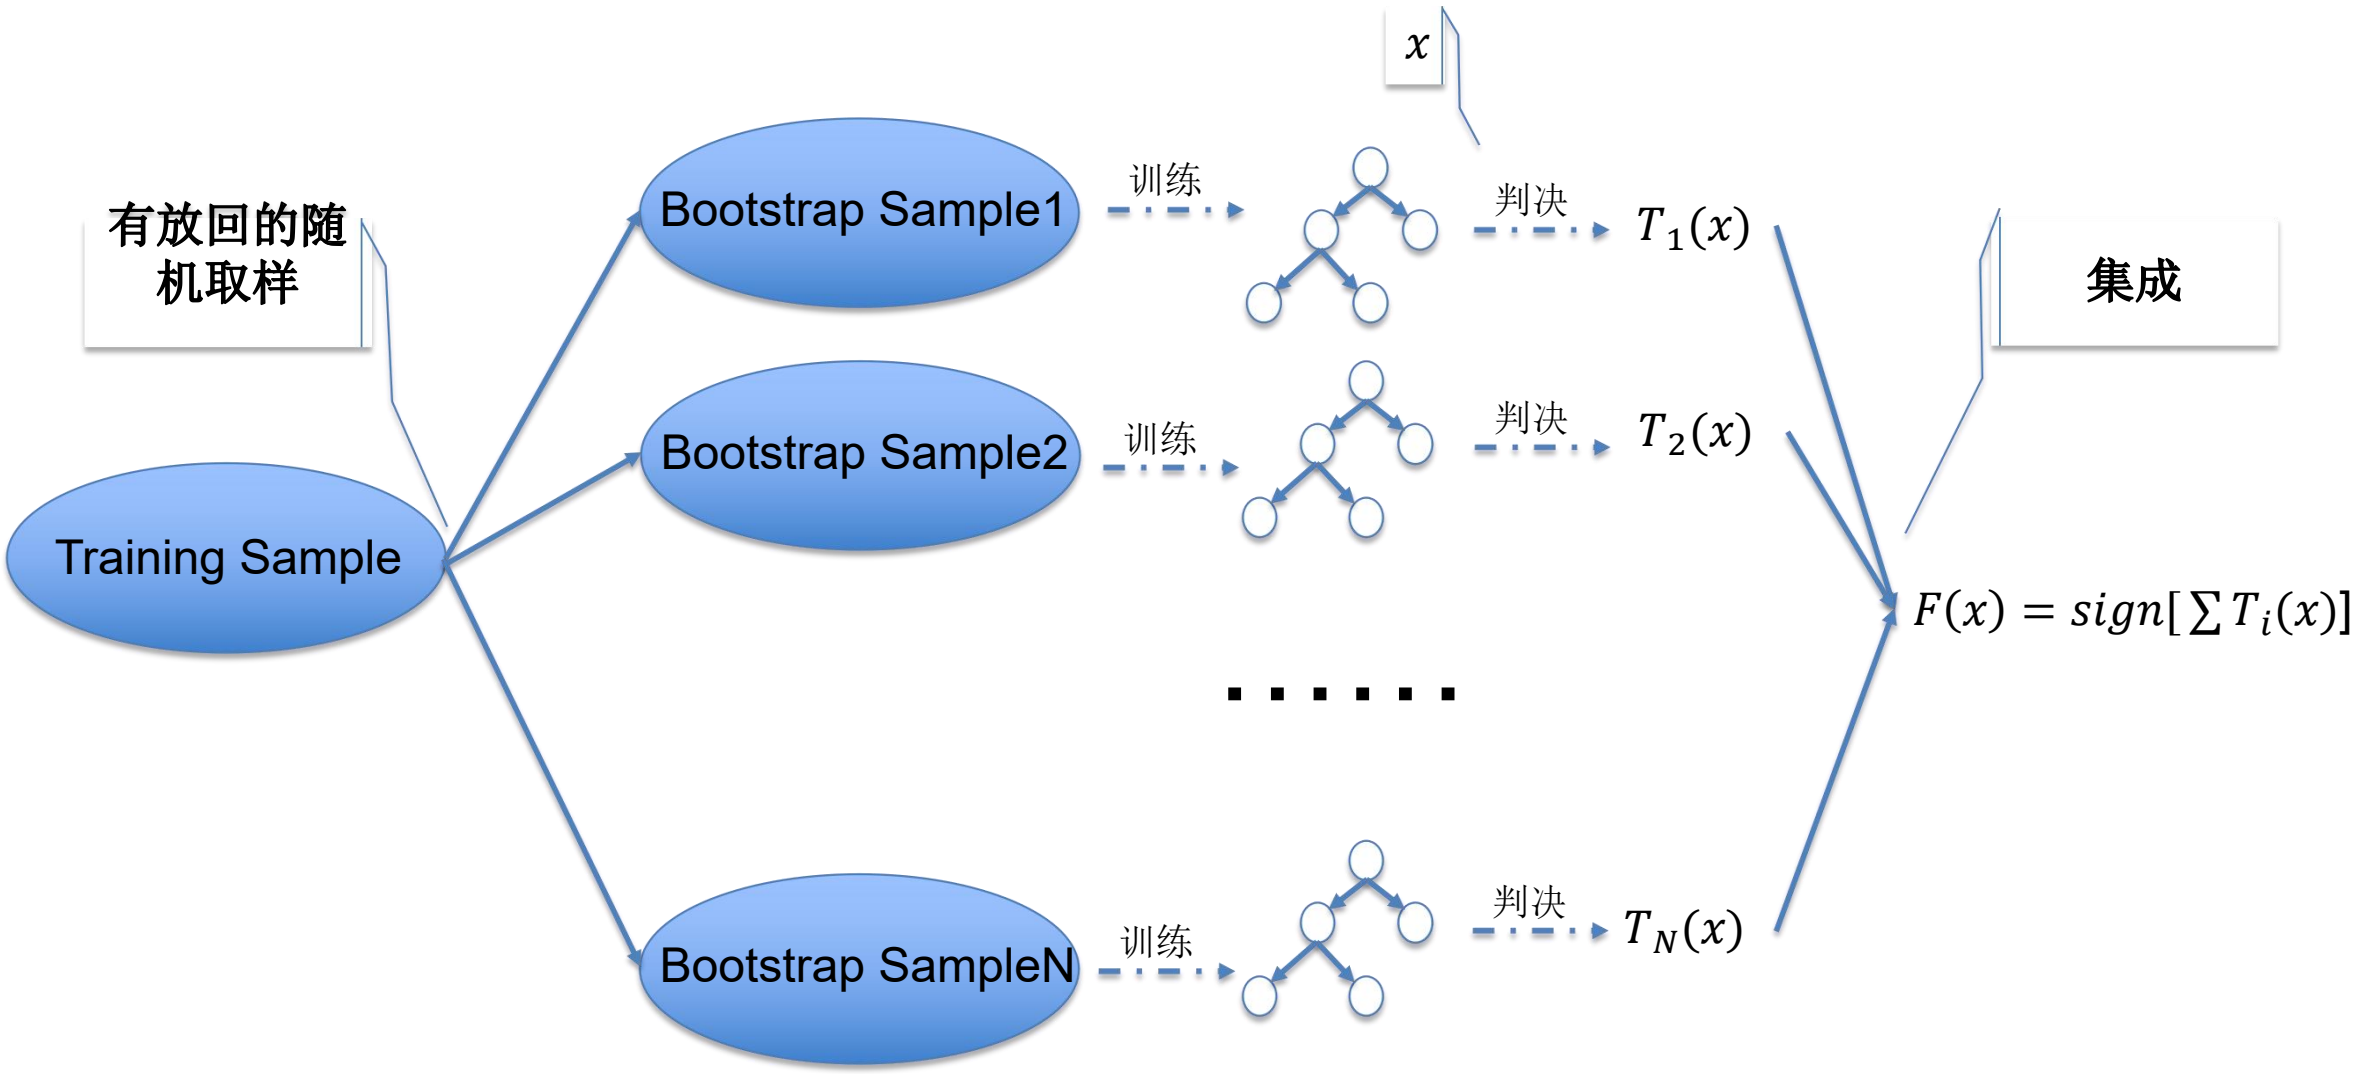
x
有放回的随机取样
Training Sample
Bootstrap Sample1
Bootstrap Sample2
Bootstrap SampleN
训练
训练
训练
判决
判决
判决
$T_1(x)$
$T_2(x)$
$T_N(x)$
集成
$F(x) = sign[\sum T_i(x)]$

机器学习分类算法

- KNN临近算法
- 决策树
- 贝叶斯分类算法
- 支持向量机SVM

贝叶斯分类算法

- 设样本有n个属性，各属性相互独立。
  - 每个样本可看作是n维空间的一个点$x=(x_1, x_2, \ldots, x_n)$。
- 有m个不同的类别， $C_1, C_2, \ldots, C_m$。
- 如果未知类别样本X分配给C_i，必定是

$$P(C_i|x) > P(C_j|x),\ 1 \le i, j \le m,\ i \ne j$$

- 贝叶斯定理

$$P(C_i|x)=P(x|C_i)P(C_i)/P(x)。$$

- 后验概率$P(C_i|X)$可转化求：$P(x|C_i)P(C_i)$

贝叶斯分类算法

Day	Outlook	Temperature	Humidity	Wind	Play ball
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

贝叶斯分类算法

- 假设属性相互**独立**。
  - 温度热不热跟湿度没有任何关系，天气是否下雨也不影响是否刮风。
- 每个属性都有相同的权重。

x =(*Sunny, Hot, Normal, Weak*)

求$P(C_i/x)$，转化为求$P(x/C_i)P(C_i)$

类别：C_1（yes）、C_2（no）

$P(C_1)$=9/14=0.643

$P(C_2)$=5/14=0.357

贝叶斯分类算法

$$P(x/C_1)=P(x_1/C_1)\,P(x_2/C_1)\,P(x_3/C_1)\,P(x_4/C_1)$$

$$=P(Sunny/C_1)\,P(Hot/C_1)\,P(Normal/C_1)\,P(Weak/C_1)$$

$$=\frac{2}{9}*\frac{2}{9}*\frac{6}{9}*\frac{6}{9}=0.022$$

$$P(x/C_1)P(C_1)=0.022*0.643=0.014$$

Day	Outlook	Play ball
D3	Overcast	Yes
D4	Rain	Yes
D5	Rain	Yes
D7	Overcast	Yes
D9	Sunny	Yes
D10	Rain	Yes
D11	Sunny	Yes
D12	Overcast	Yes
D13	Overcast	Yes

贝叶斯分类算法

$P(x|C_2)=P(x_1|C_2)\ P(x_2|C_2)\ P(x_3|C_2)\ P(x_4|C_2)$

$= P(Sunny|C_2)\ P(Hot|C_2)\ P(Normal|C_2)\ P(Weak|C_2)$

$=\frac{3}{5}*\frac{2}{5}*\frac{1}{5}*\frac{2}{5}=0.0192$

$P(x|C_2)P(C_2)=0.0192*0.357=0.0069$

$P(x|C_1)P(C_1) > P(x|C_2)P(C_2)$

x =(Sunny, Hot, Normal, Weak)适合打球。

机器学习分类算法

- KNN临近算法
- 决策树
- 贝叶斯分类算法
- 支持向量机SVM

支持向量机（Support Vector Machine, SVM）

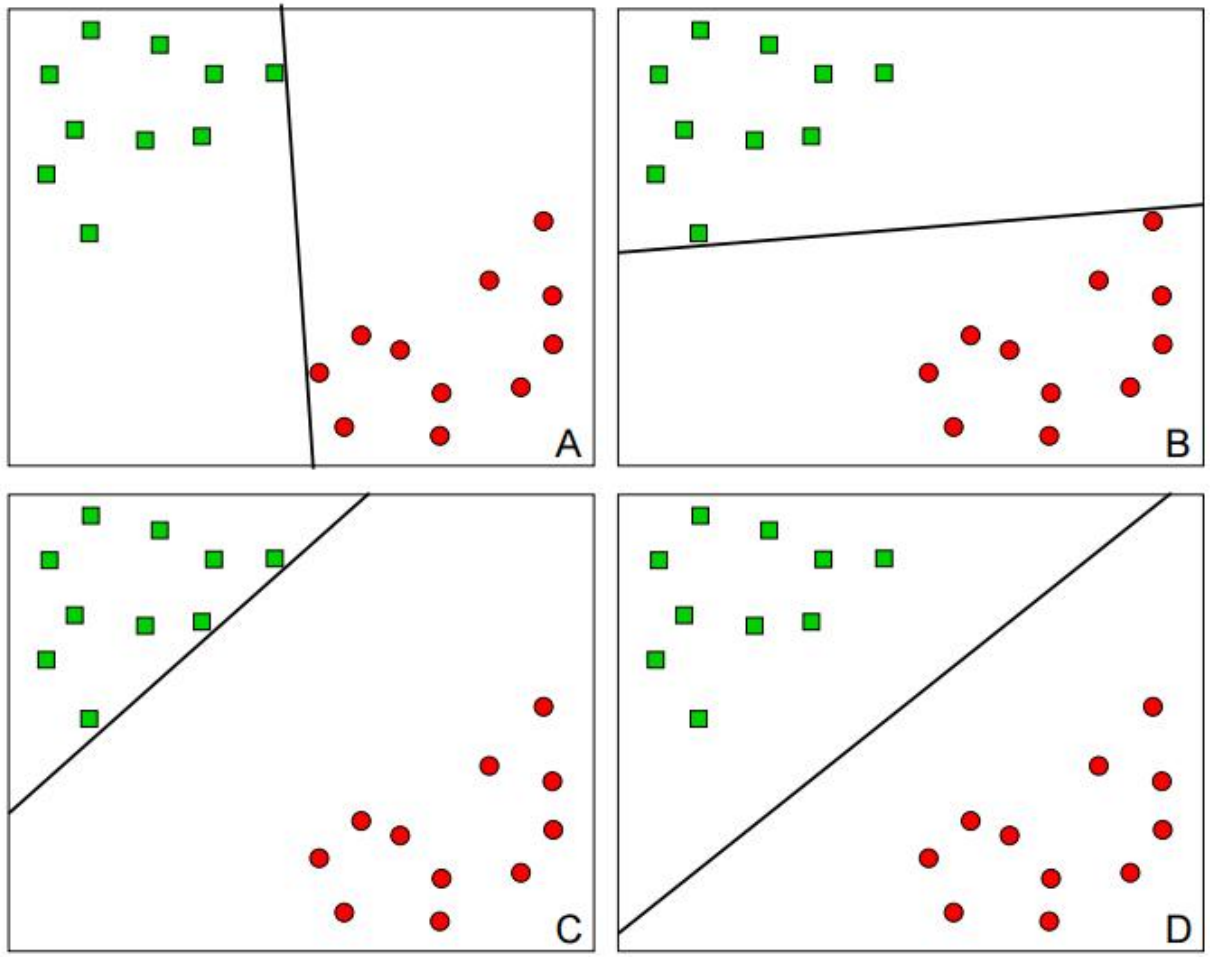

哪个分类平面最好?

支持向量机是对数据进行二元分类的广义线性分类器。

决策边界是对样本数据求解的最大边距超平面。

支持向量机

给定训练样本集D={(x_1, y_1) ，(x_2, y_2)，…..，(x_n, y_n)}，y_n ∈{-1,1}

假设有超平面使得n个样本满足

$$y_i = 1\text{时}，\ (w^{\mathrm{T}} \cdot x_i + b) > 0, i = 1, \cdots, n$$

$$y_i = -1\text{时}，\ (w^{\mathrm{T}} \cdot x_i + b) < 0, i = 1, \cdots, n$$

令(合适的缩放即可)

$$y_i = 1\text{时}，\ (w^{\mathrm{T}} \cdot x_i + b) \geq 1, i = 1, \cdots, n$$

$$y_i = -1\text{时}，\ (w^{\mathrm{T}} \cdot x_i + b) \leq -1, i = 1, \cdots, n$$

几何间隔：$\frac{2}{||w||}$

目的：最大化间隔准则，最小化训练损失。

问题转变为：

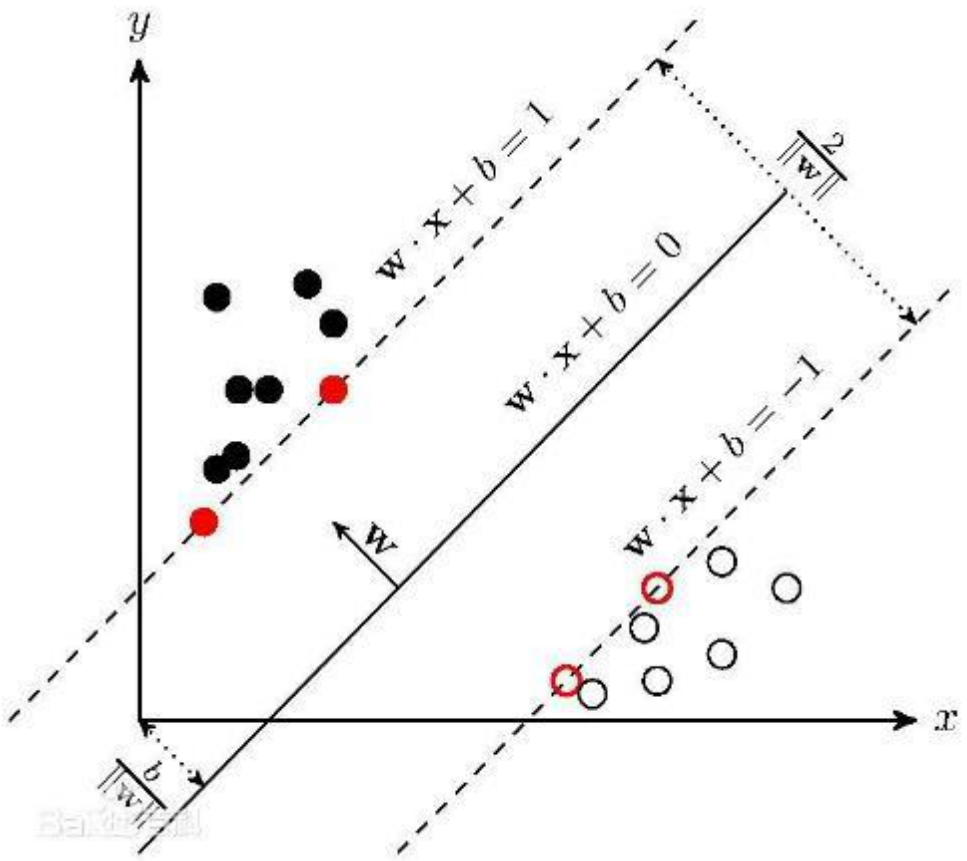

$$\min \frac{1}{||w||^2} \quad s.t.\ y_i(w^{\mathrm{T}} \cdot x_i + b) \geq 1, i = 1, \cdots, n$$

克服异常点

有几个点不满足 $y_i(\boldsymbol{w}^{\mathrm{T}} \cdot \boldsymbol{x}_i + b) \geq 1$

最大化间隔的同时，不满足约束的样本尽量少。

优化目标变为

$$\min_{w,b}\left(\frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}\ell_{0/1}(y_i(w^T x_i + b) - 1)\right)$$

0/1损失函数 $\ell_{0/1}(z) = \begin{cases} 1, & if \quad z < 0; \\ 0, & otherwise. \end{cases}$

C: 惩罚系数。 C无穷大时，新的优化目标迫使所有样本满足约束条件，等价原目标函数。 C取有限值，允许一些样本不满足约束条件。

$\ell_{0/1}$ 非凸，不连续，数学性质不好。

通常用其他函数代替，称为“替代损失”，如hinge损失：

$$\ell_{hinge}(z) = \max(0, 1 - z)$$

目标函数变为 $\min_{w,b}\left(\frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}\max(0, 1 - y_i(w^T x_i + b))\right)$

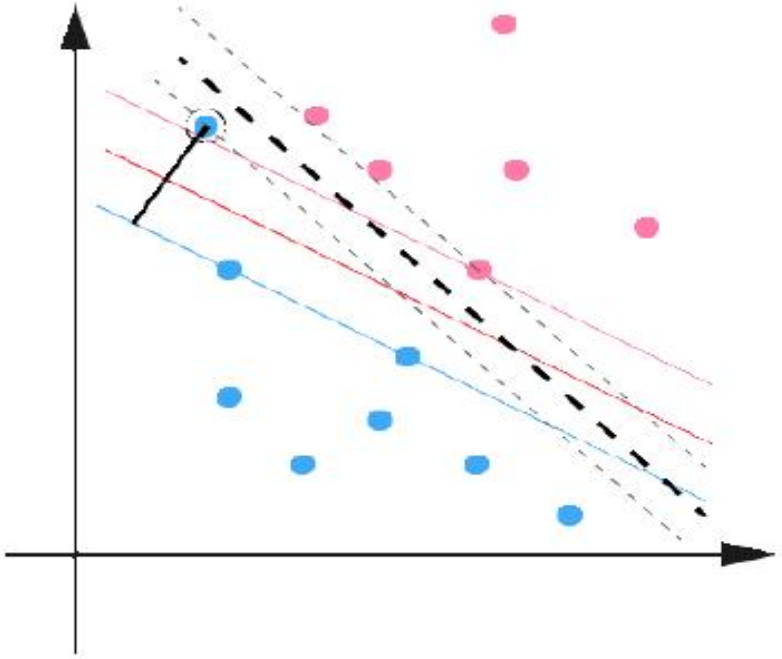

引入“松弛变量” ξ_i，目标函数

$$\min\left(\frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n}\xi_i\right)$$

$$s.t. \quad y_i(w^T x_i + b) \geq 1 - \xi_i, i = 1, \ldots, n$$

$$\xi_i \geq 0, i = 1, \ldots, n$$

线性不可分

- 核函数把输入空间映射到一个高维，乃至无穷维的特征空间。
- 在映射后的高维空间里，原来线性不可分问题变得线性可分。

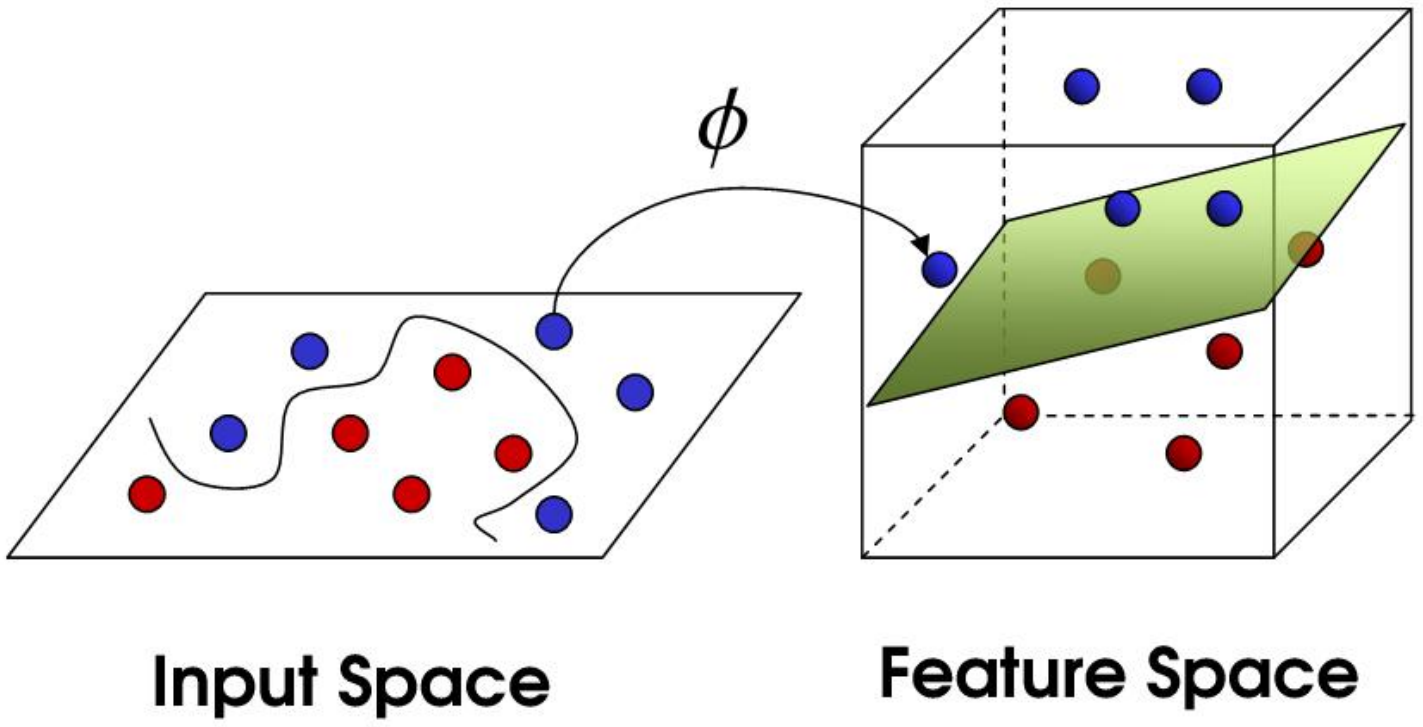

线性不可分（续）

$$\phi: R \mapsto R^2$$
$$\phi(x) = (x, x^2)$$

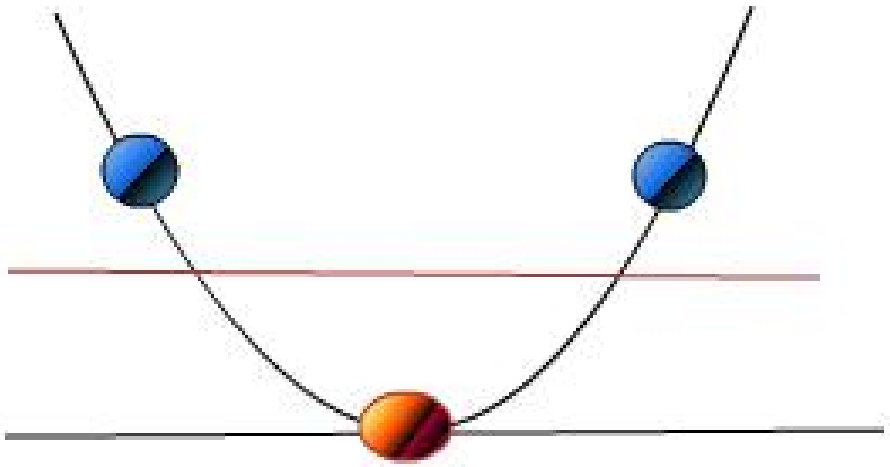

多分类问题

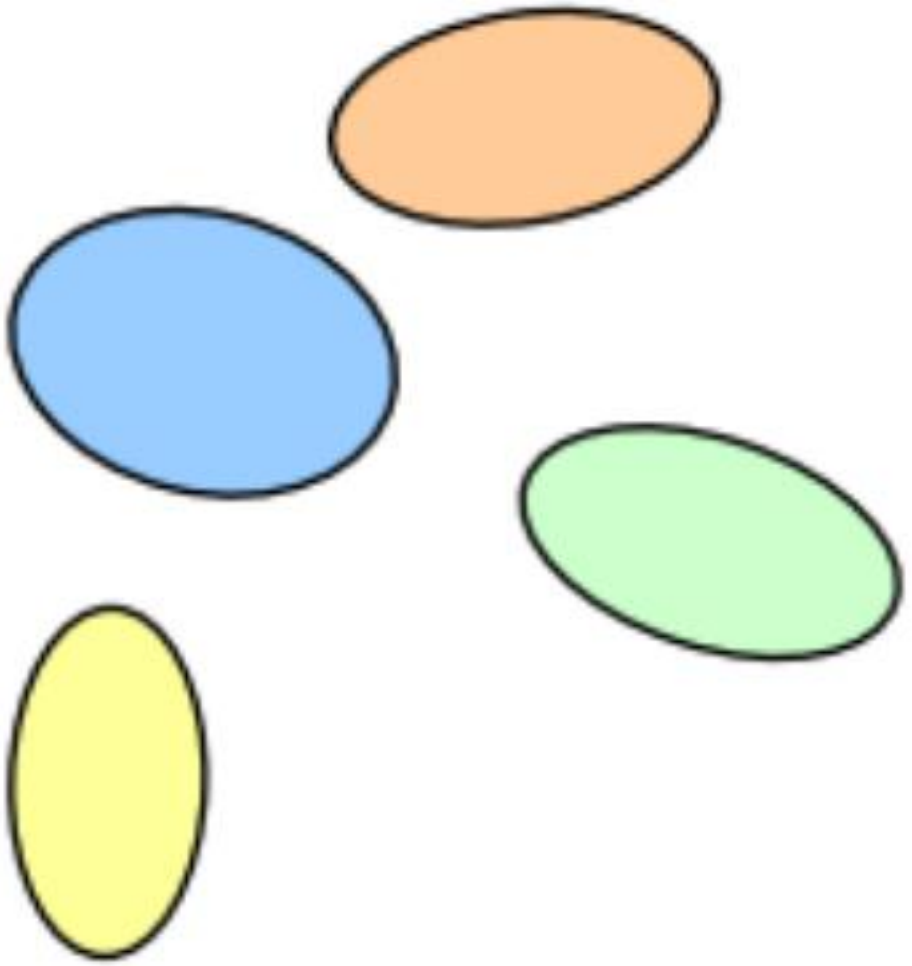

一对余 (One Against Rest, OAR)

将第i类视作正类，其他类视作负类，得到二分类器f_i，最终得到k个二分类器。新样本x经过全部分类器后， 若只有一个+1出现，则判断为相应类别；若输出不止一个+1，或者没有一个输出为+1，则比较$f_i(x), i = 1, \cdots, k$,最大者对应类别作为新样本的类别。

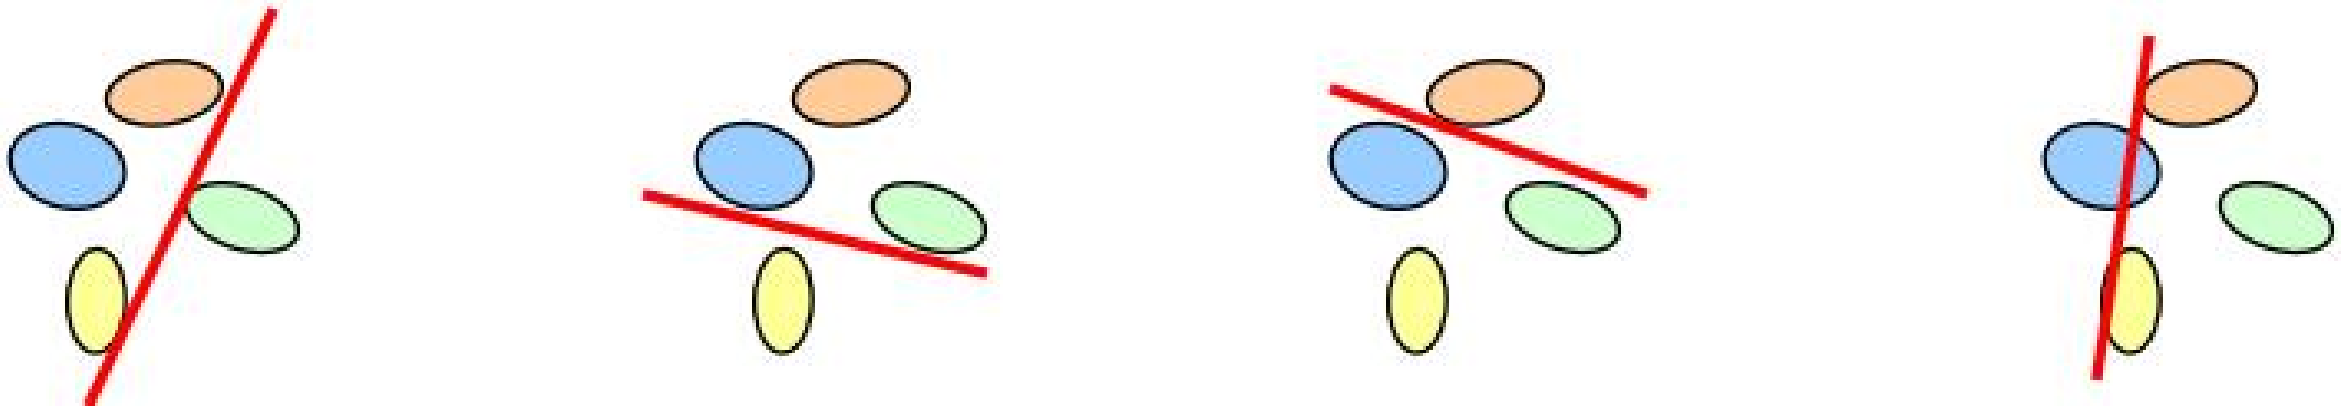

一对一(One Against One, OAO)

选取分属类别i, j的样本训练得到二分类器f_{ij}，最终得到$k(k-1)/2$个二分类器。新样本$\boldsymbol{x}$经过全部分类器，每个分类器为其“投上一票”，最后输出为得票最高的类别。

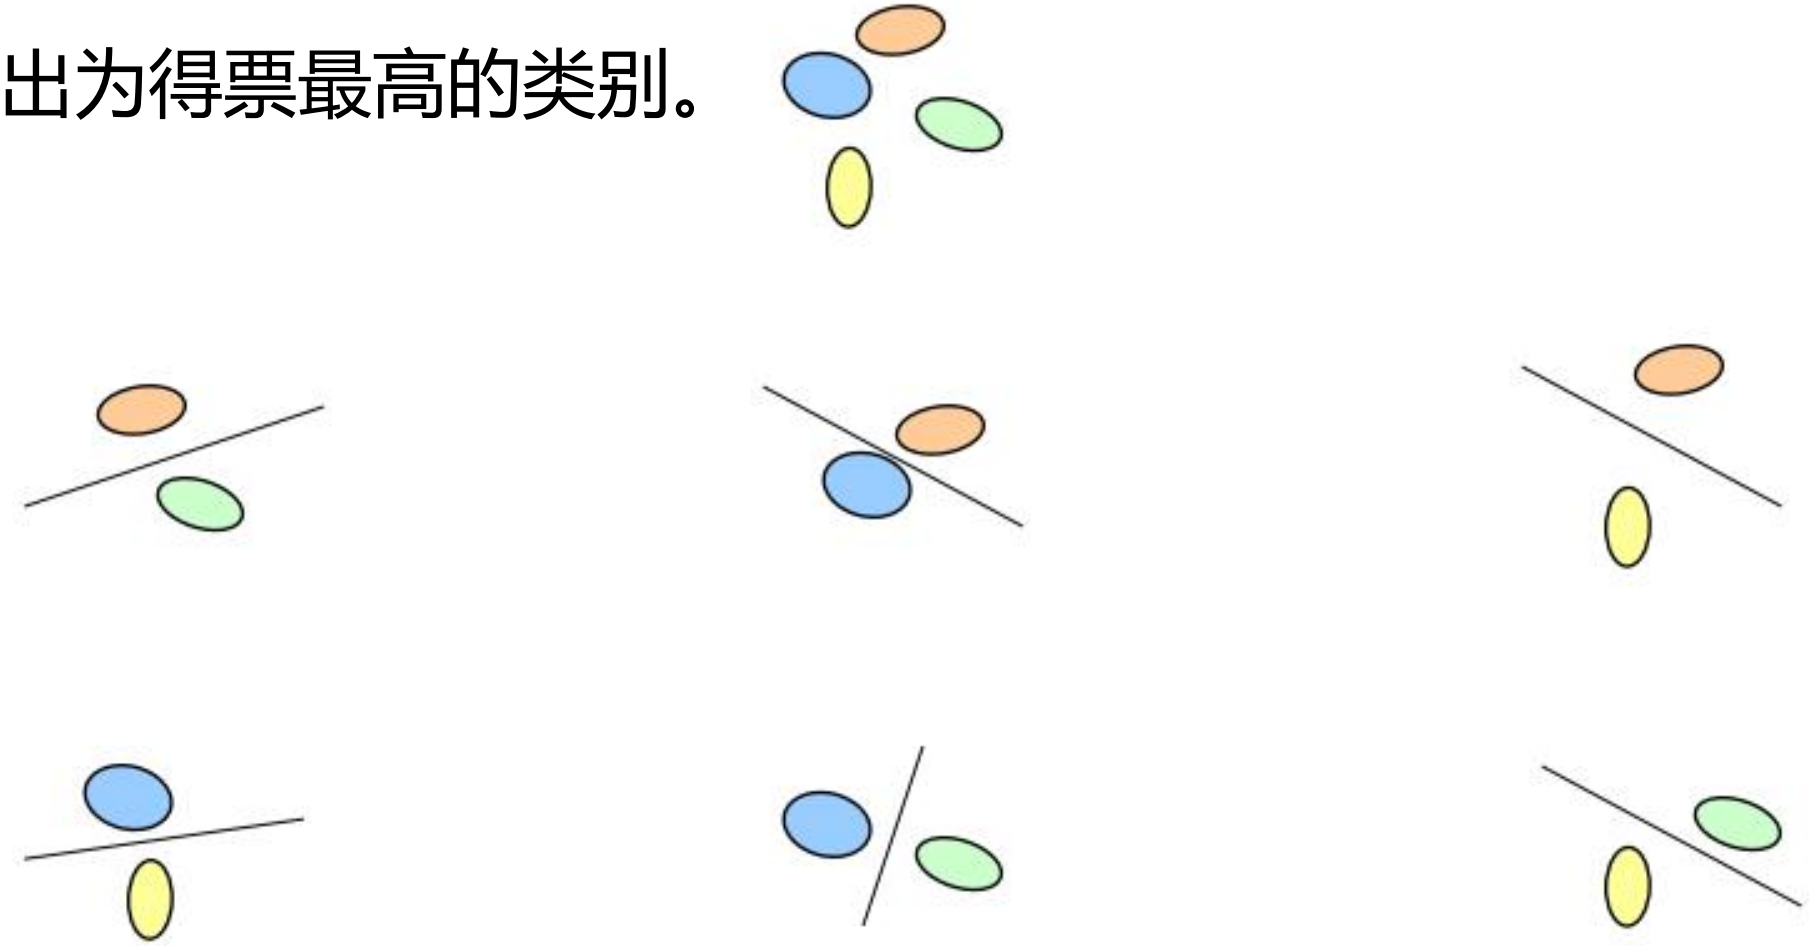

分类

- 机器学习分类算法
- 分类评估方法

分类评估方法

- X ：类别。
- X' ：分类结果。
- *true/false*：是/否判别正确。
- *positives/negatives*：是/否判定为属于X。
- *TP(True Positives, 真正)*：类别X 的流正确判定为X 的比例。
- *FN(False Negatives, 假负)*：类别X 的流错误判定为不属于X 的比例，即漏判率。
- *FP(False Positives, 假正)*：不是类别X 的流错误判定为属于X 的比例，即误判率。
- *TN(True Negatives, 真负)*：不是类别X 的流正确判定为不属于类别X 的比例。

	X'	$\overline{X}'$
X	TP	FN
$\overline{X}$	FP	TN

分类评估方法

- Accuracy（正确率）

$$\frac{TP+TN}{TP+FP+TN+FN}$$

	X'	$\overline{X}'$
X	TP	FN
$\overline{X}$	FP	TN

- Precision（查准率、精确率）

  ✓ 被识别为类别X的流中实际也是类别X的比例， $P=\frac{TP}{TP+FP}$

- Recall（查全率、召回率）

  ✓ 类别为X 的流正确分类为X 的比例， $R=\frac{TP}{TP+FN}$

分类评估方法

- PR 曲线（Precision Recall Curve）
  - ✓ 以查准率为 Y 轴，查全率为 X 轴的曲线图。
  - ✓ 若一个模型的 PR 曲线被另一个模型的曲线完全包住，则后者的效果更好。A 优于 C。

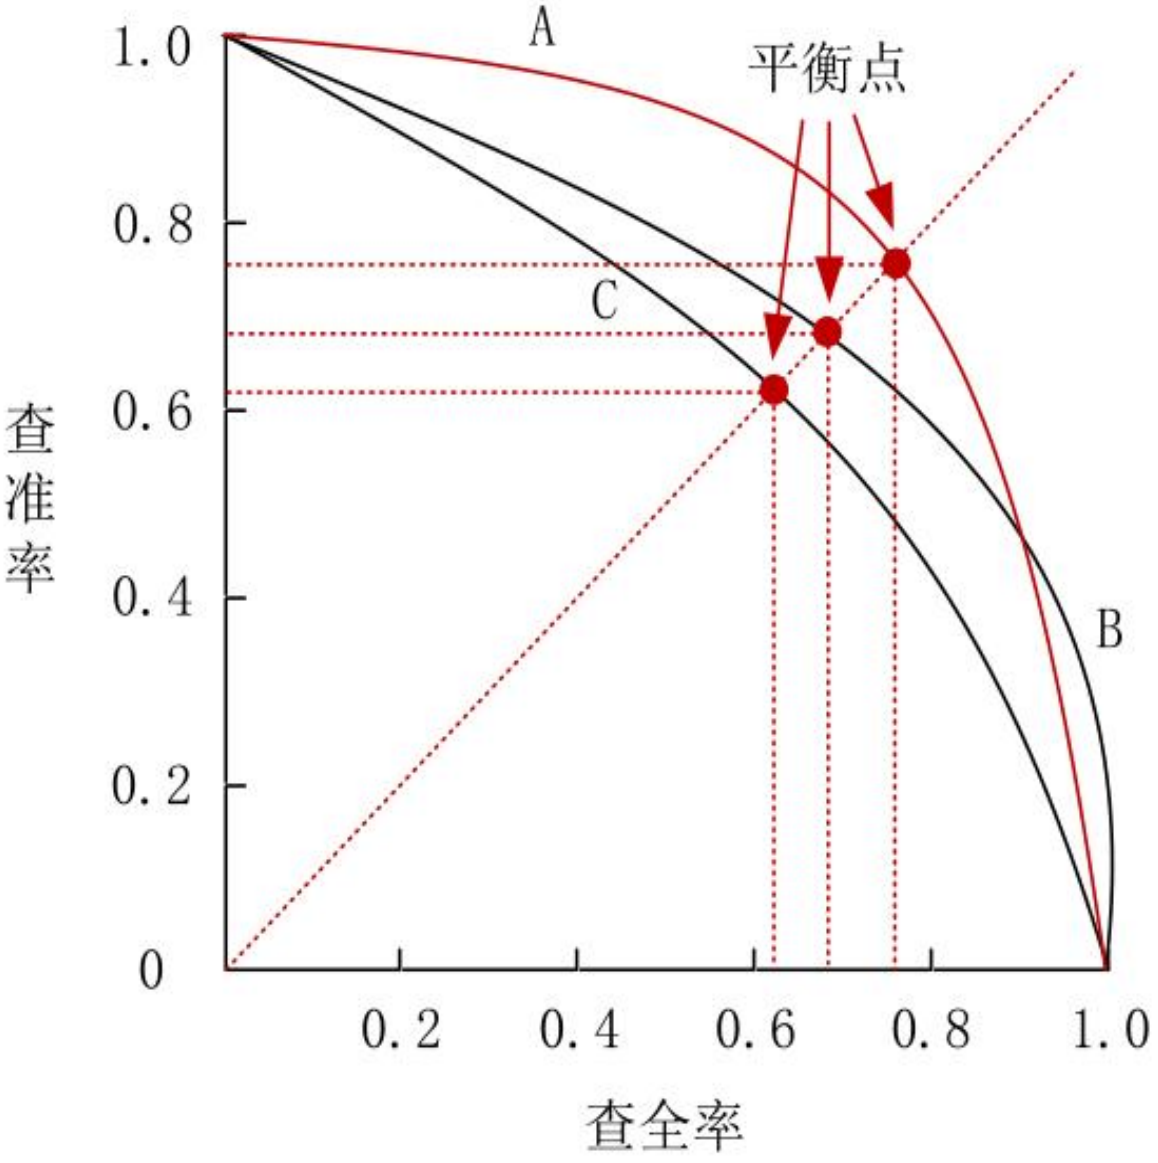

分类评估方法

- PR 曲线（Precision Recall Curve）
  - ✓ A和B哪个比较好?
    - 面积：不易计算
    - 平衡点（Break-Even Point,BEP）
      - $P=R$ 的点
    - F1度量（常用）

$$F1=\frac{2P\cdot R}{P+R}$$

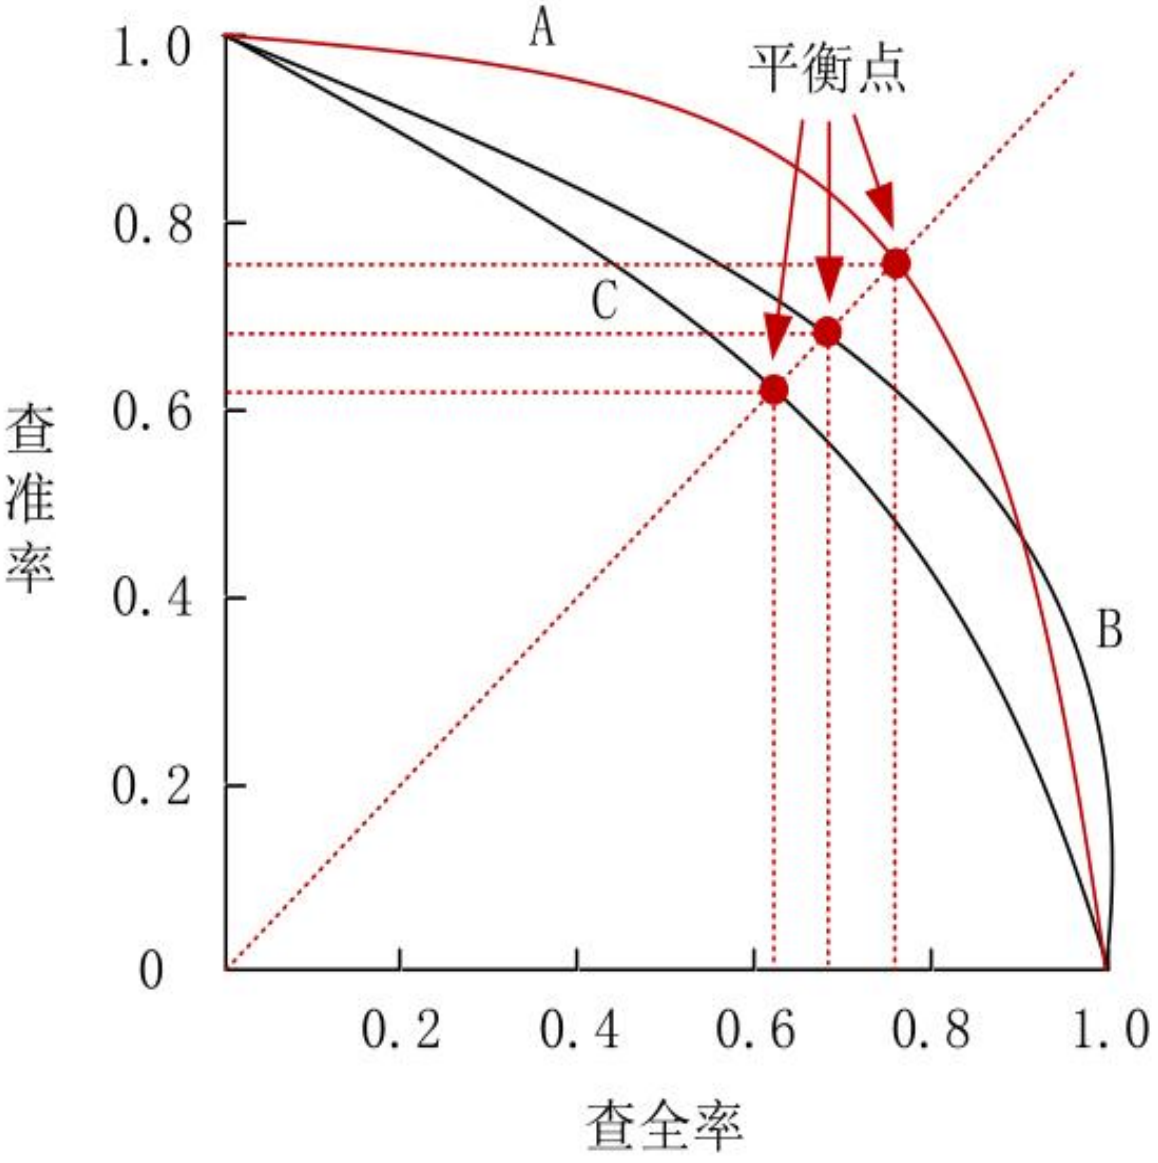

分类评估方法

- ROC 曲线与AUC
  - Receiver Operating Characteristic
  - 受试者工作特征曲线
  - AUC（Area Under Curve）
    - ◆ True Positive Rate,真正例率

$$TPR = \frac{TP}{TP + FN}$$

    - ◆ False Positive Rate假正例率

$$FPR = \frac{FP}{FP + TN}$$

	X'	$\overline{X}'$
X	TP	FN
$\overline{X}$	FP	TN

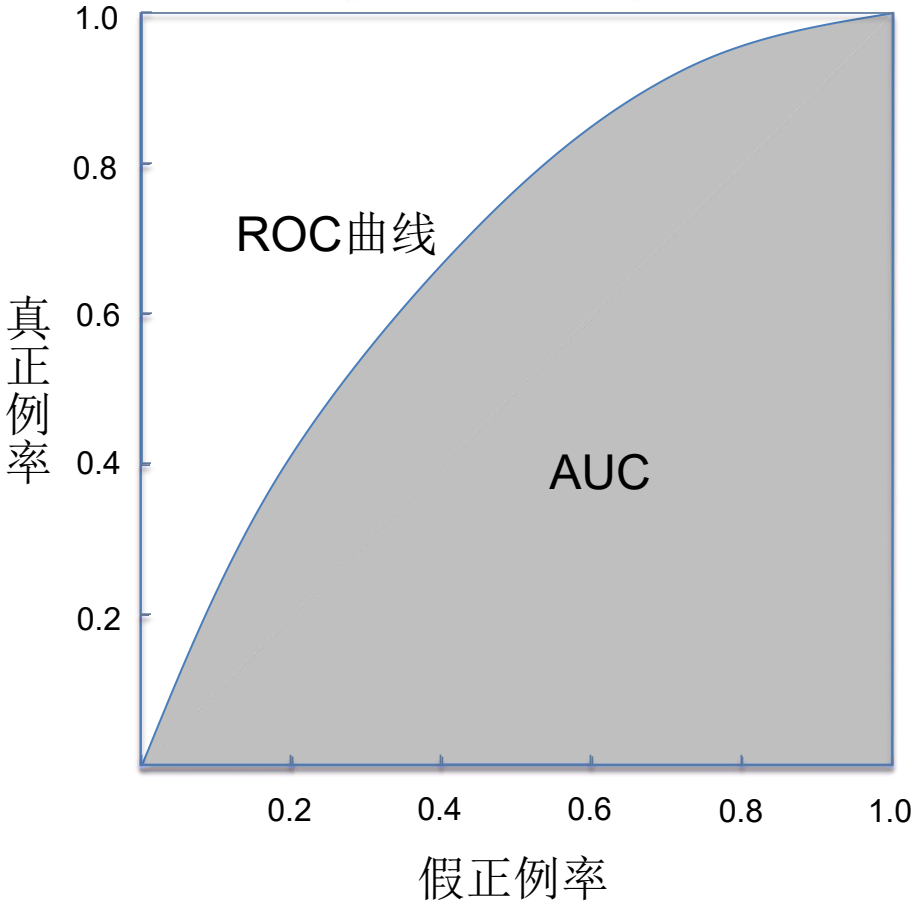

分类评估方法

- ROC 曲线与AUC
  - 若一个模型的ROC 曲线被另一个模型的曲线完全包住，那么后者的效果优于前者。
  - 比较AUC的值。

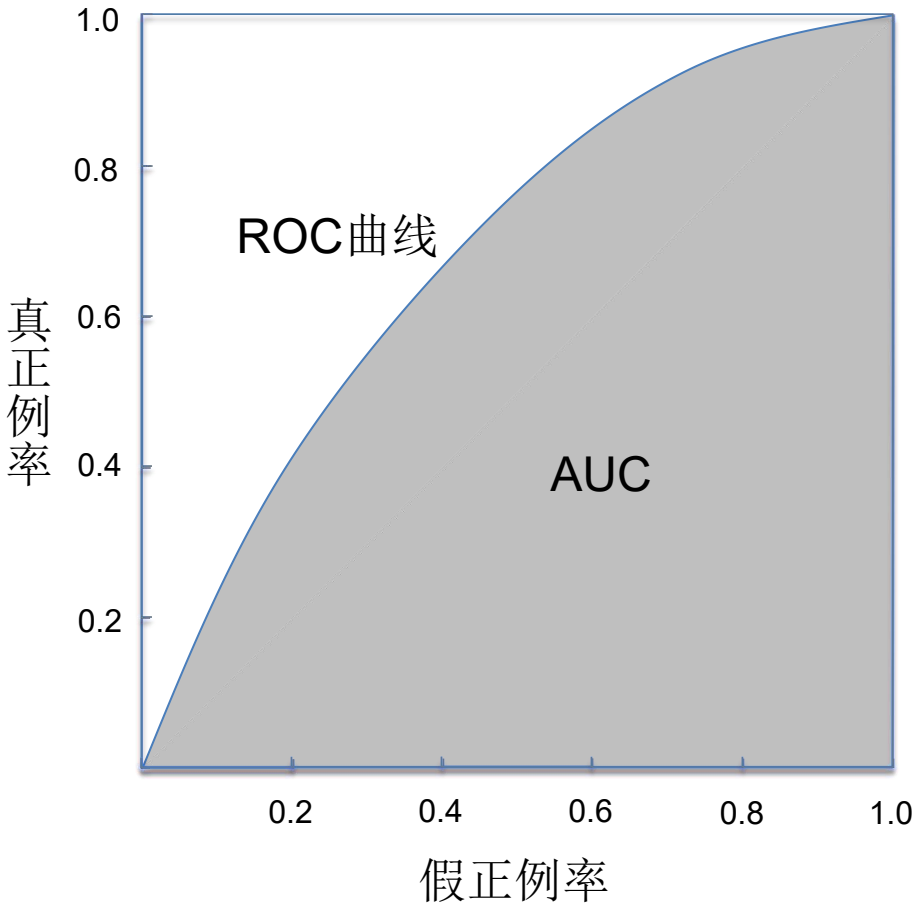

北京郵電大學
Beijing University of Posts and Telecommunications

数据科学中心
Center for Data Science