

《数据科学基础》深度学习模块·学霸笔记

典型神经网络架构（纯文字精讲版）

一、典型神经网络总览

本课程聚焦三类核心神经网络架构：

- **卷积神经网络（CNN）**：专为处理网格状数据（如图像）设计，擅长空间特征提取
- **循环神经网络（RNN）**：专为处理序列数据设计，具有时间记忆能力
- **Transformer**：基于自注意力机制，突破序列建模瓶颈，成为当前主流架构

二、卷积神经网络（CNN）

2.1 CNN基本结构流程

1 | 输入 → 卷积层 → 池化层 → [卷积/池化组合×N] → 全连接层 → 输出

- **输入层**：对原始图像进行规则化预处理（如统一尺寸、归一化）
- **卷积层**：使用离散卷积运算，通过卷积核在图像上滑动提取局部特征
- **池化层**：对特征图进行下采样（降维），保留主要信息、减少计算量
- **卷积/池化组合**：深层网络通过多层堆叠，实现从低级边缘→中级纹理→高级语义的层次化特征提取
- **全连接层**：将提取的特征表示映射到标记空间（如分类类别）
- **输出层**：产生最终预测结果（如Softmax输出分类概率）

🔥 核心思想：CNN通过"局部感知 + 权值共享 + 层次化特征提取"三大机制，高效建模图像的空间结构。

2.2 卷积层：特征提取的核心

2.2.1 卷积运算本质

- 卷积核（滤波器/权值矩阵）在输入图像上按步长滑动，在每个位置执行**元素对应相乘后求和**，生成输出特征图的一个像素
- 数学表达（以3×3卷积核、步长1为例）：

$$A[i,j] = \sigma(\sum \sum X[i+m, j+n] \times W[m,n] + b)$$

其中X为输入，W为卷积核权值，b为偏置， σ 为激活函数

2.2.2 卷积核的作用：特征检测器

- 每个卷积核专门学习检测某种特定模式（如"横折""竖钩""圆弧"等笔画特征）
- 示例：识别手写数字时，不同卷积核分别响应不同笔画组合，通过特征叠加实现数字判别
- 关键理解**：卷积核不是固定滤波器，而是通过反向传播**学习得到的可训练参数**

2.2.3 多通道卷积机制

- 输入图像可能含多通道（如RGB三通道），卷积核需匹配输入通道数
- 每个输出特征图由**一组卷积核**（数量=输入通道数）分别卷积后相加，再加偏置得到
- 输出通道数 = 该层卷积核的组数（即希望提取的特征种类数）
- 参数数量计算公式：（卷积核高 × 卷积核宽 × 输入通道数 + 1）× 输出通道数
 - 示例：3×3卷积核、3通道输入、2个输出特征 → $(3 \times 3 \times 3 + 1) \times 2 = 56$ 个参数

2.2.4 卷积的两大核心特性（纯文字解析图表要点）

◆ 局部连接 (Local Connectivity)

- 输出特征图的每个神经元**只与输入图像的局部区域**相连（由卷积核尺寸决定）
- 优势：大幅减少参数数量，避免全连接带来的维度灾难；符合图像"局部相关性"先验

◆ 权值共享 (Weight Sharing)

- 同一个卷积核在整张图像上滑动时，**参数值保持不变**
- 优势：① 参数效率极高；② 使网络具备**平移不变性**——无论特征出现在图像何处，都能被同一卷积核检测到

💡 图表核心结论：局部连接+权值共享使CNN用极少量参数（如56个）即可处理高维图像，同时保持对空间位置的鲁棒性。

2.3 池化层：特征聚合与降维

2.3.1 池化操作本质

- 在特征图上用固定窗口（如 2×2 ）按步长滑动，对窗口内数值执行聚合函数，输出单一值
- 目的：① 降低特征图尺寸，减少后续计算量；② 增强特征对微小平移/形变的鲁棒性

2.3.2 常见池化类型（纯文字解析图表要点）

◆ 最大池化 (Max Pooling)

- 操作：取窗口内最大值作为输出
- 示例： 2×2 窗口含 $[1, 1, 5, 6] \rightarrow$ 输出6
- 优势：保留最显著特征，对噪声有一定抑制作用，实践中最常用

◆ 平均池化 (Mean Pooling)

- 操作：取窗口内平均值作为输出
- 示例： $[1, 1, 5, 6] \rightarrow (1+1+5+6)/4 = 3.25$
- 优势：保留整体背景信息，适用于需要平滑特征的场景

◆ 求和池化 (Sum Pooling)

- 操作：取窗口内数值之和
- 示例： $[1, 1, 5, 6] \rightarrow 13$
- 应用较少，特定任务中可能有用

🔥 其他变体：随机池化 (Stochastic Pooling)、概率加权池化等，核心思想均为"有选择地保留关键信息"

2.3.3 池化的三大作用（纯文字解析图表要点）

◆ 作用1：特征聚合，降低计算复杂度

- 2×2 池化+步长2 $\rightarrow$ 特征图宽高各减半 $\rightarrow$ 参数量降为 $1/4$
- 为深层网络堆叠提供计算可行性

◆ 作用2：满足位置不变性 (Translation Invariance)

- 同一物体在图像中轻微移动时，池化后仍能输出相似特征响应
- 原理：池化窗口覆盖一定区域，局部位置变化不影响聚合结果
- 示例：字符"1"左移1像素，最大池化仍可能选中相同特征值

◆ 作用3：扩大感受野 (Receptive Field)

- 感受野定义：输出特征图中某像素"看到"的输入图像区域大小
- 卷积+池化交替堆叠 $\rightarrow$ 感受野逐层扩大 $\rightarrow$ 高层神经元可捕捉全局语义
- 示例推导：

- 第1层3×3卷积（步长1）→ 感受野3×3
- 接2×2池化（步长2）→ 感受野扩展至4×4
- 多层叠加后，顶层神经元可"感知"整图内容

2.4 经典CNN架构演进

架构	核心特点	历史意义
AlexNet	5卷积层+3全连接层；ReLU激活；Dropout；GPU加速	2012年ImageNet冠军，开启深度学习复兴
VGGNet	统一使用3×3小卷积核堆叠；结构规整；深度达16-19层	证明"深度+小卷积核"的有效性，成为特征提取 backbone
GoogLeNet	提出Inception模块：多尺度卷积核并行+1×1卷积降维	在控制参数量前提下提升表征能力，引入辅助损失优化训练

🔥 演进逻辑：从"加深网络"→"优化模块设计"→"平衡深度/宽度/计算效率"

2.5 CNN典型应用场景

- 交通标志识别：检测+分类道路标识
- 交通参与者识别：行人/车辆/非机动车检测与跟踪
- 场景分割：像素级语义理解（如自动驾驶环境感知）
- 其他：医学影像分析、人脸识别、工业质检等

三、循环神经网络（RNN）

3.1 RNN基本结构（展开视角）

1	时刻 t : 输入 $x_t \rightarrow$ [隐藏层 $s_t = f(U \cdot x_t + W \cdot s_{t-1})$] $\rightarrow$ 输出 $o_t = g(V \cdot s_t)$
2	↑
3	权重 W 实现 "时间递归"

- x_t : t 时刻输入（如词向量）
- s_t : t 时刻隐藏状态（承载历史信息）

- o_t : t 时刻输出 (如预测下一个词的概率分布)
- U, V, W : 三类权重矩阵, **在所有时刻共享** (核心设计)

3.2 RNN三大核心特点

◆ 时序依赖建模

- s_t 同时依赖当前输入 x_t 和历史状态 $s_{t-1} \rightarrow$ 天然适合序列数据

◆ 参数共享机制

- $U/V/W$ 跨时间步复用 $\rightarrow$ 参数量与序列长度无关, 可处理任意长序列

◆ 隐式记忆功能

- 隐藏状态 s_t 理论上可编码从 x_1 到 x_t 的全部历史信息 (理想情况)

3.3 RNN的数学本质：历史信息递归展开

通过递归代入隐藏层公式, 可得:

$$1 \quad s_t = \sigma(U \cdot x_t + W \cdot \sigma(U \cdot x_{t-1} + W \cdot \sigma(U \cdot x_{t-2} + \dots)))$$

- $\rightarrow$ 输出 o_t 实际受 $x_t, x_{t-1}, x_{t-2}, \dots$ 共同影响
- $\rightarrow$ 激活函数 σ (如 $\tanh$) 引入非线性, 使网络具备复杂映射能力

💡 关键理解: RNN通过"时间展开"将序列建模转化为深层前馈网络, 但共享参数使其具备时序归纳偏置。

3.4 RNN的优势与局限

✅ 优势场景: 短序列依赖建模

- 示例: "中国女排 主教练 是 ? "
- 分析: 预测"? "处只需近期上下文 ("主教练"), RNN可有效捕捉

❌ 核心局限: 长时依赖问题 (Long-Term Dependency)

- 示例: 长文本情感判断 ("莫雷事件... (万字) ...我们决定不看 ? ")

- 问题根源：

1. 梯度消失/爆炸：反向传播时梯度经多次连乘→趋近0或无穷
2. 信息稀释：早期输入信号经多层非线性变换后被"淹没"
3. 简单结构限制：单tanh层难以选择性记忆/遗忘

3.5 LSTM：解决长时依赖的里程碑设计

3.5.1 核心思想

- 引入**细胞状态** C_t 作为"长期记忆通道"，与隐藏状态 h_t (短期输出) 分离
- 通过**门控机制** (遗忘门/输入门/输出门) 实现"选择性记忆更新"

3.5.2 四大组件纯文字解析 (图表要点转化)

◆ 细胞状态 (Cell State) C_t

- 类比"传送带"：贯穿整个序列，信息可低损耗流动
- 作用：专门存储长期依赖信息，避免梯度消失

◆ 遗忘门 (Forget Gate)

- 输入：上一时刻隐藏状态 h_{t-1} + 当前输入 x_t
- 输出：0~1之间的向量 f_t (sigmoid激活)
- 作用：决定"细胞状态 C_{t-1} 中哪些信息需要丢弃"
- 公式： $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$

◆ 输入门 (Input Gate)

- 两部分协同：
 - (1) 门控向量 $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \rightarrow$ 决定"更新哪些位置"
 - (2) 候选值 $\hat{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \rightarrow$ 生成"待写入的新内容"
- 作用：控制新信息如何融入细胞状态

◆ 细胞状态更新

- $C_t = f_t \odot C_{t-1} + i_t \odot \hat{C}_t$
- $\odot$ 表示逐元素相乘
- 本质：**遗忘旧信息 + 写入新信息** 的加权融合

◆ 输出门 (Output Gate)

- $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \rightarrow$ 决定"输出细胞状态的哪些部分"
- $h_t = o_t \odot \tanh(C_t) \rightarrow$ 生成当前隐藏状态 (即LSTM输出)

💡 LSTM核心优势：通过门控实现"有目的的记忆管理"，显著缓解长时依赖问题。

3.6 RNN进阶变体

◆ 双向RNN (Bi-RNN)

- 结构：正向RNN + 反向RNN 并行，输出拼接
- 优势：t时刻输出可同时利用"过去"和"未来"上下文
- 适用：序列标注、机器翻译等需全局上下文的任务
- 示例："The cat ___ on the mat" → 填"sat"需同时看前后文

◆ 深度RNN (Deep RNN)

- 结构：单时间步内堆叠多个RNN隐藏层
- 优势：增强非线性建模能力，提取层次化时序特征
- 注意：需更多数据+正则化，避免过拟合

3.7 RNN/LSTM典型应用场景


- 机器翻译：Encoder编码源语言序列 → Decoder生成目标语言（注意：早期模型需接收完整输入后才开始输出）
- 图像描述生成：CNN提取图像特征 → RNN生成自然语言描述
 - 成功案例："A group of people playing soccer"
 - 失败案例：细节错误（数量/颜色/动作误判），反映模型对细粒度理解仍有限
- 视觉问答（VQA）：联合理解图像内容+自然语言问题，输出答案

四、Transformer：注意力革命

4.1 核心突破

- 彻底摒弃循环/卷积，纯基于自注意力机制（Self-Attention）建模序列
- 优势：① 并行计算效率高；② 长距离依赖建模能力强；③ 可解释性好（注意力权重可视化）

4.2 总体架构: Encoder-Decoder框架



- **Encoder**: 将输入序列编码为富含语义的表示序列
- **Decoder**: 自回归生成输出, 每一步可"关注"Encoder全部输出

4.3 核心组件纯文字解析

◆ Multi-Head Attention (多头注意力)

- 思想: 将查询/键/值投影到多个子空间, 并行计算多组注意力, 最后拼接融合
- 优势:
 - (1) 捕捉不同位置的关联模式 (如语法依赖/语义共指)
 - (2) 增强模型表达能力, 避免单注意力头的信息瓶颈
- 计算流程:

1	1. 线性投影: $Q = XW^Q, K = XW^K, V = XW^V$
2	2. 缩放点积注意力: $\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$
3	3. 多头拼接: $\text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$

◆ Add & Norm (残差连接 + 层归一化)

- 结构: $x \rightarrow \text{SubLayer}(x) \rightarrow \text{Add}(x + \text{SubLayer}(x)) \rightarrow \text{LayerNorm} \rightarrow \text{输出}$
- 作用:
 - (1) 残差连接: 缓解深层网络梯度消失, 促进信息流动
 - (2) 层归一化: 加速训练收敛, 提升模型稳定性
- 位置: 每个Attention和前馈网络后均添加

◆ Positional Encoding (位置编码)

- 问题: Transformer无递归/卷积, 天然不具备位置感知能力
- 方案: 向输入嵌入添加正弦/余弦函数生成的位置向量
- 效果: 使模型能利用序列顺序信息, 且可泛化到更长序列

4.4 Decoder特殊设计：掩码自注意力 (Masked Self-Attention)

- 目的：保证训练时Decoder第t步**只能关注≤t的位置**，避免"偷看未来"
- 实现：在计算注意力权重时，将未来位置的分数设为 $-\infty$ ，Softmax后概率为0
- 意义：确保自回归生成的因果性，与推理阶段行为一致

五、三类架构对比总结

维度	CNN	RNN/LSTM	Transformer
核心机制	局部卷积+池化	时序递归+门控记忆	全局自注意力
数据偏好	网格数据（图像/视频）	序列数据（文本/语音/时间序列）	任意序列（尤其长序列）
并行能力	高（空间并行）	低（时间步串行）	极高（全序列并行）
长程依赖	通过深层堆叠间接实现	LSTM可缓解，但仍有瓶颈	原生支持，效果最优
位置感知	卷积核天然具备	时序顺序隐含位置	需显式添加位置编码
典型任务	图像分类/检测/分割	语言建模/机器翻译/语音识别	机器翻译/文本生成/多模态理解

 学习建议：理解每类架构的**设计动机**→**核心组件**→**适用边界**，避免死记结构；关注"为什么需要这个模块"比"这个模块怎么算"更重要。

注：本笔记严格依据课件内容整理，剔除所有非知识性元素，图表信息已转化为纯文字要点描述，适用于深度学习理论基础复习与知识内化。